



## **SKRIPSI**

# **SEGMENTASI POLA PEMBAYARAN PELANGGAN PROPERTI PADA PT XYZ MENGUNAKAN METODE *X-MEANS***

**EDELIN FORTUNA**  
NPM 21083010087

### **DOSEN PEMBIMBING**

Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T., IPU., Asean, Eng.  
Kartika Maulida Hindrayani, S.Kom., M.Kom.

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI SAINS DATA  
SURABAYA  
2025**



**SKRIPSI**

**SEGMENTASI POLA PEMBAYARAN  
PELANGGAN PROPERTI PADA PT XYZ  
MENGUNAKAN METODE *X-MEANS***

**EDELIN FORTUNA**  
NPM 21083010087

**DOSEN PEMBIMBING**

Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T., IPU., Asean, Eng.  
Kartika Maulida Hindrayani, S.Kom., M.Kom.

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI SAINS DATA  
SURABAYA  
2025**



## **SKRIPSI**

# **SEGMENTASI POLA PEMBAYARAN PELANGGAN PROPERTI PADA PT XYZ MENGUNAKAN METODE X-MEANS**

**EDELIN FORTUNA**  
NPM 21083010087

## **DOSEN PEMBIMBING**

Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T., IPU., Asean, Eng.  
Kartika Maulida Hindrayani, S.Kom., M.Kom.

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI SAINS DATA  
SURABAYA  
2025**

## LEMBAR PENGESAHAN

### SEGMENTASI POLA PEMBAYARAN PELANGGAN PROPERTI PADA PT XYZ MENGGUNAKAN METODE X-MEANS

Oleh:  
EDELIN FORTUNA  
NPM. 21083010087

Telah dipertahankan di hadapan dan diterima oleh Tim Penguji Sidang Skripsi Program Studi Sains Data Fakultas Ilmu Komputer Universitas Pembangunan Nasional Veteran Jawa Timur Pada tanggal 10 September 2025.

Menyetujui,

Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T.,  
IPU., Asean, Eng.  
NIP. 19801205 200501 1 002

  
.....


(Pembimbing I)

Kartika Maulida Hindrayani, S.Kom., M.Kom.  
NIP. 19920909 202203 2 009

  
.....

(Pembimbing II)

Dr. Ir. Mohammad Idhom, S.P., S.Kom., M.T.  
NIP. 19830310 202121 1 006

  
.....

(Ketua Penguji)

Alfan Rizaldy Pratama, S.Tr.T., M.Tr.Kom.  
NIP. 19990606 202406 1 001

  
.....

(Penguji I)

Mengetahui,

Dekan Fakultas Ilmu Komputer


  
  
d Prof. Dr. Ir. Novirina Hendrasarie, MT.  
NIP. 19681126 199403 2 001

**LEMBAR PERSETUJUAN**

**SEGMENTASI POLA PEMBAYARAN PELANGGAN PROPERTI PADA  
PT XYZ MENGGUNAKAN METODE X-MEANS**

Oleh:  
**EDELIN FORTUNA**  
**NPM. 21083010087**

Telah disetujui untuk mengikuti Ujian Skripsi



**Menyetujui,**

**Koordinator Program Studi Sains Data  
Fakultas Ilmu Komputer**

**Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T., IPU., Asean, Eng.**  
**NIP. 19801205 200501 1 002**



## SURAT PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini:

Nama Mahasiswa : Edelin Fortuna  
NPM : 21083010087  
Program : Sarjana (S1)  
Program Studi : Sains Data  
Fakultas : Fakultas Ilmu Komputer

Menyatakan bahwa dalam dokumen ilmiah Skripsi ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan secara lengkap dalam daftar pustaka.

Dan saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi. Apabila di kemudian hari ditemukan indikasi plagiat pada Skripsi ini, saya bersedia menerima sanksi sesuai dengan peraturan perundang-undangan yang berlaku.

Demikian surat pernyataan ini saya buat dengan sesungguhnya tanpa ada paksaan dari siapapun juga dan untuk dipergunakan sebagaimana mestinya



Surabaya, 11 September 2025  
Yang Membuat Pernyataan,



EDELIN FORTUNA  
NPM. 21083010087

## ABSTRAK

Nama Mahasiswa / NPM : Edelin Fortuna / 21083010087  
Judul Proposal Skripsi : Segmentasi Pola Pembayaran Pelanggan Properti  
Pada PT XYZ Menggunakan Metode *X-Means*  
Dosen Pembimbing : 1. Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T.,  
IPU., Asean, Eng.  
2. Kartika Maulida Hindrayani, S.Kom., M.Kom.

Memahami perilaku pelanggan sangat penting untuk mendukung keberlangsungan bisnis properti. Penelitian ini bertujuan untuk mengelompokkan pelanggan PT XYZ berdasarkan pola pembayaran angsuran mereka dengan menggunakan algoritma klasterisasi *X-Means*. Sebanyak 9.615 catatan transaksi di integrasi menjadi 386 profil pelanggan dan dianalisis menggunakan fitur yang telah dipilih karena menggambarkan karakteristik individual pembeli, seperti jumlah keterlambatan pembayaran dan status pembayaran. *X-Means* dipilih karena memiliki efisiensi dalam komputasi membentuk klaster. Proses klasterisasi menghasilkan 3 klaster. Dilakukan evaluasi klaster dengan menggunakan metrik evaluasi *Silhouette Score* diperoleh 0,606, *Davies Bouldin Index* (DBI) sebesar 0,538, dan *Calinski Harabsz* sebesar 472.924 yang menunjukkan pemisahan klaster dapat dikategorikan cukup baik. Hasil klasterisasi ini memiliki pola pelanggan yang melakukan transaksi pembayaran sekali langsung lunas, pelanggan yang masih menunggu, pelanggan yang telat bayar. Beragam karakteristik pelanggan, dapat dimanfaatkan untuk merancang strategi komunikatif kepada pelanggan, mengoptimalkan proses penagihan, serta meningkatkan pengelolaan hubungan pelanggan secara keseluruhan guna mendukung pertumbuhan bisnis perusahaan.

**Kata kunci:** Klasterisasi, Pelanggan, Pola Pembayaran, Segmentasi *Silhouette Score*, *X-Means*

*Halaman ini sengaja dikosongkan*



## ***ABSTRACT***

*Student Name / NPM* : Edelin Fortuna / 21083010087  
*Thesis Title* : *Segmentation of Customer Payment Patterns in Property at PT XYZ Using the X-Means Method*  
*Advisor* : 1. Dr. Eng. Ir. Dwi Arman Prasetya, S.T., M.T.,  
IPU., Asean, Eng.  
2. Kartika Maulida Hindrayani, S.Kom., M.Kom.

*Understanding customer behavior is essential to support the sustainability of the property business. This study aims to segment the customers of PT XYZ based on their installment payment patterns using the X-Means Clustering algorithm. A total of 9,615 transaction records were integrated into 386 customer profiles and analyzed using selected features that represent individual buyer characteristics, such as the number of late payments and payment status. X-Means was chosen due to its computational efficiency in forming clusters. The Clustering process resulted in third clusters. Cluster evaluation was conducted using three metrics: the Silhouette Score 0.606, Davies-Bouldin Index 0,538, and Calinski-Harabasz score 472.924, indicating that the cluster separation is reasonably good. The Clustering results revealed distinct customer patterns, including those who make a single full payment, those with outstanding balances, and those with frequent payment delays. These diverse customer characteristics can be leveraged to design targeted communication strategies, optimize the billing process, and enhance overall customer relationship management, ultimately supporting the company's business growth.*

***Keywords:*** *Clustering, Payment Pattern, Segmentation, Silhouette Score, X-Means Clustering*

*Halaman ini sengaja dikosongkan*

## KATA PENGANTAR

Puji syukur kehadiran Allah SWT atas segala rahmat, hidayah dan karunia-Nya kepada penulis sehingga skripsi berjudul **“Segmentasi Pola Pembayaran Pelanggan Properti Pada PT XYZ Menggunakan Metode X-Means”** dapat terselesaikan dengan baik. Penulis mengucapkan terima kasih kepada Bapak Dr. Eng. Ir. Dwi Arman Prasetya., ST., MT., IPU., Asean. Eng dan juga Bu Kartika Maulida Hindrayani, S.Kom., M.Kom., selaku dosen pembimbing saya yang telah meluangkan waktunya untuk membimbing dan memberikan kritik serta saran yang membangun, nasihat serta motivasi kepada penulis. Dan penulis juga banyak menerima bantuan dari berbagai pihak, baik itu berupa moril, spiritual maupun materiil. Untuk itu penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. Ir. Akhmad Fauzi, MMT., IPU., ASEAN. Eng., selaku Rektor Universitas Pembangunan Nasional “Veteran” Jawa Timur.
2. Ibu Prof. Dr. Ir. Novirina Hendrasarie, MT., beserta jajarannya selaku Dekan dan Wakil Dekan Fakultas Ilmu Komputer Universitas Pembangunan Nasional “Veteran” Jawa Timur.
3. Bapak Dr. Eng. Ir. Dwi Arman Prasetya., ST., MT., IPU., Asean. Eng., selaku Koordinator Program Studi Sains Data Fakultas Ilmu Komputer Universitas Pembangunan Nasional “Veteran” Jawa Timur.
4. Dosen-dosen Program Studi Sains Data yang telah membimbing serta memberikan arahan selama masa perkuliahan.
5. Kedua orang tua penulis yang selalu senantiasa mendoakan dan mendukung penulis, memberikan nasihat-nasihat yang membuat penulis bisa menyelesaikan penelitian dan buku skripsi ini.
6. Kedua kakak penulis Rani dan Ame serta adik penulis Aurel yang selalu membeikan dukungan dalam bentuk apapun demi menyelesaikan penelitian dan buku skripsi ini.
7. Kepada sahabat-sahabat penulis, Aisyah, Putri, Dzakiyyah, Bella, Dona, Azrel, Made Ayu, Lila, sahabat kecil penulis Syifa, Alvira, dan Diana yang selalu memberikan pertolongan apapun saat penulis kesusahaan dan menemani penulis saat mengerjakan buku skripsi ini.

8. Kepada teman-teman kuliah penulis, Nayya, Awal, Cesaria, Firly, Novita, dan Radya yang telah memberikan dukungan serta selalu mengajak penulis untuk melakukan bimbingan dan memberikan kritik masukan kepada penulis dikala kebingungan dalam menyelesaikan penelitian ini.
9. Himpunan Mahasiswa Sains Data yang telah memberikan pengalaman baru yang berkesan dan tak terlupakan kepada penulis saat masa perkuliahan berlangsung.
10. Seluruh angkatan 2021 Program Studi Sains Data Universitas Pembangunan Nasional “Veteran” Jawa Timur.
11. Dan yang terakhir, kepada diri saya sendiri, apresiasi sebesar-besarnya karena telah bertanggung jawab atas pilihan yang diambil untuk menyelesaikan apa yang telah dimulai. Terima kasih telah bertahan, mau terus berusaha dan berjuang sehingga tidak pantang menyerah dalam situasi dan kondisi apapun.

Penulis menyadari bahwa di dalam penyusunan skripsi ini masih terdapat kekurangan. Untuk itu kritik dan saran yang membangun dari semua pihak sangat diharapkan demi kesempurnaan penulisan buku skripsi ini. Dengan segala keterbatasan yang penulis miliki semoga penelitian ini dapat bermanfaat bagi seluruh pihak yang membaca buku skripsi ini.

Surabaya, 10 September 2025

Penulis

## DAFTAR ISI

|                                                |             |
|------------------------------------------------|-------------|
| <b>HALAMAN SAMPUL.....</b>                     | <b>i</b>    |
| <b>LEMBAR PENGESAHAN .....</b>                 | <b>ii</b>   |
| <b>LEMBAR PERSETUJUAN .....</b>                | <b>iii</b>  |
| <b>SURAT PERNYATAAN BEBAS PLAGIASI.....</b>    | <b>iv</b>   |
| <b>ABSTRAK .....</b>                           | <b>v</b>    |
| <b><i>ABSTRACT</i> .....</b>                   | <b>vii</b>  |
| <b>KATA PENGANTAR.....</b>                     | <b>ix</b>   |
| <b>DAFTAR ISI.....</b>                         | <b>xi</b>   |
| <b>DAFTAR GAMBAR.....</b>                      | <b>xv</b>   |
| <b>DAFTAR TABEL .....</b>                      | <b>xvii</b> |
| <b>DAFTAR LAMPIRAN .....</b>                   | <b>xix</b>  |
| <b>DAFTAR NOTASI.....</b>                      | <b>xxi</b>  |
| <b>BAB I PENDAHULUAN.....</b>                  | <b>1</b>    |
| 1.1. Latar Belakang .....                      | 1           |
| 1.2. Rumusan Masalah .....                     | 5           |
| 1.3. Batasan Masalah.....                      | 5           |
| 1.4. Tujuan Penelitian .....                   | 6           |
| 1.5. Manfaat Penelitian .....                  | 6           |
| <b>BAB II TINJAUAN PUSTAKA.....</b>            | <b>9</b>    |
| 2.1 Penelitian Terdahulu .....                 | 9           |
| 2.2 Dasar Teori.....                           | 14          |
| 2.2.1. Properti.....                           | 14          |
| 2.2.2. <i>Inhouse</i> Syariah.....             | 15          |
| 2.2.3. Segmentasi .....                        | 15          |
| 2.2.4. Klasterisasi .....                      | 17          |
| 2.2.5. <i>K-Means</i> .....                    | 18          |
| 2.2.6. <i>X-Means</i> .....                    | 19          |
| 2.2.7. <i>RobustScaler</i> .....               | 21          |
| 2.2.8. <i>Sillhouette Score</i> .....          | 22          |
| 2.2.9. <i>Davies Bouldin Index (DBI)</i> ..... | 23          |

|                                                                |           |
|----------------------------------------------------------------|-----------|
| 2.2.10. <i>Calinski Harabasz</i> .....                         | 24        |
| <b>BAB III DESAIN DAN IMPLEMENTASI SISTEM.....</b>             | <b>27</b> |
| 3.1 Variabel Penelitian dan Sumber Data.....                   | 27        |
| 3.2. Langkah Analisis .....                                    | 28        |
| 3.2.1 Identifikasi Masalah .....                               | 28        |
| 3.2.2 Persiapan Data .....                                     | 29        |
| 3.2.3 <i>Preprocessing</i> Data .....                          | 31        |
| 3.3.3 Explorasi Data Analisis .....                            | 32        |
| 3.3.4 Implementasi <i>X-Means</i> .....                        | 34        |
| 3.3.5 Evaluasi Model.....                                      | 35        |
| 3.3.6 Interpretasi Kluster .....                               | 37        |
| 3.3.7 Visualisasi Kluster .....                                | 37        |
| 3.3.8 Rekomendasi Strategi.....                                | 39        |
| 3.3. Desain Sistem .....                                       | 39        |
| <b>BAB IV HASIL DAN PEMBAHASAN.....</b>                        | <b>43</b> |
| 4.1. Persiapan Data .....                                      | 43        |
| 4.1.1. Membaca Data.....                                       | 43        |
| 4.1.2. Seleksi Fitur.....                                      | 44        |
| 4.1.3. <i>Missing Value</i> .....                              | 46        |
| 4.1.4. Konversi Tipe Data.....                                 | 47        |
| 4.1.5. Agregasi dan Penggabungan Data.....                     | 48        |
| 4.1.6. <i>Missing Value</i> .....                              | 53        |
| 4.2. Data <i>Preprocessing</i> .....                           | 55        |
| 4.2.1. Transformasi Data .....                                 | 55        |
| 4.2.2. Standarisasi Data .....                                 | 57        |
| 4.3. Explorasi Data Analisis .....                             | 60        |
| 4.3.1. Analisis Distribusi .....                               | 60        |
| 4.3.2. Identifikasi <i>Outlier</i> .....                       | 63        |
| 4.3.3. Korelasi <i>Pearson</i> .....                           | 66        |
| 4.3.4. Menghitung <i>Variance Inflation Factor</i> (VIF) ..... | 68        |
| 4.4. Implementasi <i>X-Means</i> .....                         | 70        |
| 4.5. Evaluasi Model <i>X-Means</i> .....                       | 73        |



|                             |                                                                               |           |
|-----------------------------|-------------------------------------------------------------------------------|-----------|
| 4.6.                        | Perbandingan Waktu Komputasi <i>X-Means</i> dan <i>K-Means</i> .....          | 75        |
| 4.7.                        | Interpretasi Klaster .....                                                    | 75        |
| 4.8.                        | Visualisasi Klaster.....                                                      | 77        |
| 4.9.                        | Kontribusi dan Pemanfaatan, Rekomendasi, serta Implementasi Strategi<br>..... | 80        |
| 4.10.                       | <i>Deployment</i> .....                                                       | 82        |
| <b>BAB V PENUTUP .....</b>  |                                                                               | <b>85</b> |
| 5.1.                        | Kesimpulan .....                                                              | 85        |
| 5.2.                        | Saran Pengembangan .....                                                      | 86        |
| <b>DAFTAR PUSTAKA .....</b> |                                                                               | <b>87</b> |
| <b>LAMPIRAN.....</b>        |                                                                               | <b>91</b> |

*Halaman ini sengaja dikosongkan*

## DAFTAR GAMBAR

|                                                                            |    |
|----------------------------------------------------------------------------|----|
| Gambar 2.1. Ilustrasi Segementasi Pelanggan[23] .....                      | 16 |
| Gambar 2.2. Ilustrasi <i>Clustering</i> [24] .....                         | 18 |
| Gambar 3.1. Diagram Alir Penelitian .....                                  | 28 |
| Gambar 3.2. Diagram alir Desain Sistem.....                                | 41 |
| Gambar 4.1. Distribusi Jumlah Transaksi.....                               | 61 |
| Gambar 4.2. Distribusi Total Pembayaran.....                               | 61 |
| Gambar 4.3. Distribusi Harga .....                                         | 62 |
| Gambar 4.4. Distribusi Selisih .....                                       | 62 |
| Gambar 4.5. Distribusi Jumlah Terlambat .....                              | 63 |
| Gambar 4.6. <i>Box Plot</i> Jumlah Transaksi.....                          | 64 |
| Gambar 4.7. <i>Box Plot</i> Total Pembayaran.....                          | 64 |
| Gambar 4.8. <i>Box Plot</i> Harga .....                                    | 65 |
| Gambar 4.9. <i>Box Plot</i> Selisih .....                                  | 65 |
| Gambar 4.10. <i>Box Plot</i> Jumlah terlambat .....                        | 66 |
| Gambar 4.11. Korelasi <i>Pearson</i> .....                                 | 68 |
| Gambar 4.12. Anggota Klaster.....                                          | 77 |
| Gambar 4.13. Jumlah Pelanggan Berdasarkan Klaster dan Status Pembayaran... | 78 |
| Gambar 4.14. t-SNE Persebaran Klaster.....                                 | 79 |
| Gambar 4.15. Halaman Utama.....                                            | 82 |
| Gambar 4.16. Fitur Web .....                                               | 83 |
| Gambar 4.17. Halaman Fitur Data .....                                      | 84 |
| Gambar 4.18. Halaman Fitur Analisis & Klasterisasi.....                    | 84 |

*Halaman ini sengaja dikosongkan*

## DAFTAR TABEL

|                                                        |    |
|--------------------------------------------------------|----|
| Tabel 2.1. Tabel Penelitian Terdahulu .....            | 9  |
| Tabel 3.1. Metadata.....                               | 27 |
| Tabel 4.1. Data Angsuran.....                          | 44 |
| Tabel 4.2. Data Utama .....                            | 44 |
| Tabel 4.3. Pemilihan Data Angsuran pertama .....       | 45 |
| Tabel 4.4. Pemilihan Data Utama .....                  | 45 |
| Tabel 4.5. Pemilihan Data Angsuran Kedua.....          | 46 |
| Tabel 4.6. <i>Output Missing Value</i> .....           | 47 |
| Tabel 4.7. Agregasi df1 .....                          | 49 |
| Tabel 4.8. Hasil Gabungan df1 dan df2 .....            | 50 |
| Tabel 4.9. Hasil Perhitungan Selisih Pembayaran .....  | 50 |
| Tabel 4.10. Penambahan Status Pembayaran.....          | 51 |
| Tabel 4.11. Perhitungan Keterlambatan Pembayaran ..... | 52 |
| Tabel 4.12. Jumlah Terlambat Setiap Unit.....          | 52 |
| Tabel 4.13. Dataset Analisis.....                      | 53 |
| Tabel 4.14. Melihat <i>Missing Value</i> .....         | 54 |
| Tabel 4.15. Dataset Penelitian.....                    | 55 |
| Tabel 4.16. Data Hasil <i>Encoding</i> .....           | 56 |
| Tabel 4.17. Penjelasan Fitur.....                      | 57 |
| Tabel 4.18. Dataset Standarisasi .....                 | 59 |
| Tabel 4.19. Perhitungan VIF .....                      | 69 |
| Tabel 4.20. Perhitungan VIF Setelah Diatasi.....       | 70 |
| Tabel 4.21. Dataset.....                               | 71 |
| Tabel 4.22. Perbandingan Waktu Komputasi .....         | 75 |
| Tabel 4.23. Kontribusi dan Pemanfaatan Strategi.....   | 80 |
| Tabel 4.24. Rekomendasi Strategi .....                 | 81 |
| Tabel 4.25. Contoh Implementasi Nyata .....            | 81 |

*Halaman ini sengaja dikosongkan*

## DAFTAR LAMPIRAN

|                                                            |    |
|------------------------------------------------------------|----|
| Lampiran 1. Data Penelitian.....                           | 91 |
| Lampiran 2. Kode <i>Script</i> .....                       | 92 |
| Lampiran 3. <i>Script</i> Pembuatan <i>Interface</i> ..... | 93 |
| Lampiran 4. LoA Artikel.....                               | 94 |

*Halaman ini sengaja dikosongkan*



## DAFTAR NOTASI

|                                |                                                                                                  |
|--------------------------------|--------------------------------------------------------------------------------------------------|
| $k$                            | : Jumlah klaster                                                                                 |
| $c_i$                          | : Himpunan data diklaster $i$                                                                    |
| $x$                            | : Vektor data                                                                                    |
| $\mu_i$                        | : <i>Centroid</i> klaster                                                                        |
| $C_{m(q)}$                     | : <i>Centroid</i> dari klaster $m$ pada perhitungan ke $q$                                       |
| $n_m$                          | : Banyaknya data pada klaster $m$                                                                |
| $x_{i(q)}$                     | : Data ke $i$ pada iterasi ke $q$                                                                |
| $BIC$                          | : Metrik statistik <i>Bayesian Information Criterion</i>                                         |
| $L$                            | : Faktor bobot                                                                                   |
| $\frac{p}{2}$                  | : Jumlah klaster                                                                                 |
| $\log N$                       | : Jumlah data titik                                                                              |
| $\frac{n}{2}$                  | : Jumlah data                                                                                    |
| $d$                            | : Dimensi data                                                                                   |
| $\sigma^2$                     | : Variansi dalam klaster                                                                         |
| $\mu$                          | : Mean (rata-rata) dari distribusi data (pusat)                                                  |
| $x_i$                          | : Data ke $i$                                                                                    |
| $\ x_i - \mu\ ^2$              | : Jarak kuadrat ( <i>squared Euclidean distance</i> ) antara data ke $i$ dengan mean (rata-rata) |
| $\sum_{i=1}^n \ x_i - \mu\ ^2$ | : Total jarak kuadrat semua data terhadap mean (rata-rata)                                       |
| $\frac{n}{2} \log(2\pi)$       | : Konstanta normalisasi Gaussian                                                                 |
| $SSE$                          | : Total error kuadrat dari semua titik ke <i>centroid</i>                                        |
| $n$                            | : Jumlah titik dalam klaster                                                                     |
| $x'$                           | : <i>Scaling robustscaller</i>                                                                   |
| $x$                            | : Nilai asli data                                                                                |
| $IQR$                          | : Rentang antar kuartil                                                                          |
| $Q3$                           | : Kuartil 3, nilai persentil ke-75 (75% data terbawah)                                           |
| $Q1$                           | : Kuartil 1, nilai persentil ke-25 (25% data terbawah)                                           |

|                            |                                                                                               |
|----------------------------|-----------------------------------------------------------------------------------------------|
| $s(i)$                     | : <i>Silhouette score</i> untuk data ke $i$                                                   |
| $b(i)$                     | : Rata-rata jarak antara data $i$ dengan klaster terdekat lainnya (klaster tetangga terdekat) |
| $a(i)$                     | : Rata-rata jarak antara data $i$ dengan semua data lain dalam klaster yang sama              |
| $\max(a(i), b(i))$         | : Normalisasi supaya nilai $s(i)$ selalu berada antara -1 sampai +1                           |
| $DBI$                      | : Metrik statistik <i>Davies Bouldin Index</i>                                                |
| $\frac{1}{k}$              | : Jumlah klaster                                                                              |
| $s_i$                      | : Rata-rata jarak antara setiap titik data dalam klaster $i$ terhadap pusat klaster           |
| $s_j$                      | : Rata-rata jarak antara setiap titik data dalam klaster $j$ terhadap pusat klaster           |
| $M_{ij}$                   | : Jarak antara pusat klaster                                                                  |
| $\frac{s_i + s_j}{M_{ij}}$ | : Perhitungan rasio kemiripan antara klaster $i$ dan $j$                                      |
| $CH$                       | : Calinski Harabasz                                                                           |
| $Tr(B_k)$                  | : <i>Trace</i> atau jumlah diagonal dari matriks disperse antar klaster                       |
| $Tr(W_k)$                  | : <i>Trace</i> dari matriks disperse dalam klaster                                            |
| $n$                        | : Jumlah total data                                                                           |
| $k$                        | : Jumlah klaster                                                                              |

# **BAB I**

## **PENDAHULUAN**

### **1.1. Latar Belakang**

Penjualan properti memiliki peran penting dalam perekonomian, tidak hanya sebagai bentuk investasi, tetapi juga sebagai penyedia kebutuhan dasar masyarakat [1]. Permintaan akan hunian maupun tempat usaha terus meningkat seiring dengan pertumbuhan jumlah penduduk. Di tengah persaingan tersebut, setiap perusahaan properti dituntut untuk memiliki keunggulan agar mampu menarik minat pelanggan. Perusahaan dapat melakukan berbagai upaya untuk menarik dan mempertahankan pelanggan, salah satunya melalui pemberian pelayanan yang sesuai dengan karakteristik pelanggan yang beragam. Pemahaman terhadap pelanggan dapat dilakukan melalui pengenalan kebutuhan, preferensi, maupun pola perilaku mereka, termasuk perilaku pembayaran saat membeli unit properti [2].

Pola pembayaran pelanggan memberikan gambaran mengenai komitmen pelanggan dalam mempertanggungjawabkan properti yang telah dibeli [3]. Hal tersebut menjadi penting untuk dianalisis karena mencerminkan tingkat kedisiplinan, komitmen pelanggan dalam memenuhi kewajiban cicilan. Analisis terhadap pola ini menjadi penting karena hasilnya tidak hanya berpengaruh pada stabilitas keuangan perusahaan, tetapi juga dapat membantu merumuskan strategi komunikasi, penagihan, dan pelayanan yang tepat sasaran. Dengan memahami perilaku pembayaran, perusahaan dapat mengalokasikan sumber daya secara lebih terarah, menjaga retensi pelanggan potensial, sekaligus menyusun strategi khusus untuk pelanggan yang dinilai berisiko.

PT XYZ adalah sebuah perusahaan properti yang beroperasi di daerah Sidoarjo, Jawa Timur. Perusahaan ini membangun sebuah perumahan di beberapa titik wilayah dengan menjual berbagai jenis unit rumah dan ruko. Sistem pembayaran yang diterapkan adalah *inhouse* syariah, yaitu tanpa keterlibatan pihak bank, tanpa bunga, dan tanpa penalti denda. Dengan sistem ini, risiko utama perusahaan terletak pada keterlambatan pembayaran cicilan pelanggan, karena perusahaan tidak memiliki instrumen bunga atau penalti sebagai kompensasi keterlambatan. Kondisi tersebut berpotensi mengganggu arus kas perusahaan serta

meningkatkan risiko piutang tak tertagih. Oleh karena itu, penelitian ini dilakukan guna menganalisis karakteristik pelanggan PT XYZ berdasarkan data historis pembayaran dan mengelompokkan pelanggan ke dalam segmen tertentu.

Ketidaktahuan terhadap pola pembayaran pelanggan berisiko menyebabkan strategi penagihan yang tidak efektif, salah sasaran dalam pelayanan, serta meningkatkan risiko kerugian jangka Panjang [4]. Oleh karena itu, diperlukan analisis berbasis segmentasi pelanggan untuk mengelompokkan mereka sesuai dengan karakteristiknya. [5]. Segmentasi pelanggan adalah pendekatan yang dapat digunakan untuk memahami perilaku pelanggan [6]. Analisis segmentasi data paling sering menggunakan teknik klasterisasi. Klasterisasi adalah pengelompokan data *unsupervised learning*, yaitu pengelompokan data tanpa adanya label atau kategori pada data tersebut [7]. Proses klasterisasi dilakukan dengan teknik data *mining* dilanjutkan dengan implementasi model untuk klasterisasi. Hal ini membantu dalam mengekstraksi informasi dari data pembayaran pelanggan dan dikelompokkan sesuai dengan karakteristiknya.

Tujuan dari klasterisasi pelanggan ialah dapat lebih memahami dan mengerti target pelanggan yang dinilai potensial atau berisiko dalam pola pembayaran serta perusahaan dapat merancang program loyalitas untuk pelanggan yang memberikan nilai tinggi bagi perusahaan [8]. Oleh karena itu, klasterisasi tidak hanya merupakan teknik dalam pengelompokan data tetapi juga teknik yang efektif untuk mendukung strategi bisnis berbasis data. Tetapi, untuk melakukan analisis ini tidaklah mudah, karena data pelanggan dan transaksi yang semakin hari semakin banyak jumlahnya, hal tersebut menjadi tantangan tersendiri dalam melakukan penelitian ini. Maka dari itu, diperlukannya sebuah metode yang tepat untuk membantu proses analisis menjadi efisien untuk data yang memiliki pola bervariasi.

Ada beberapa metode yang sering digunakan dalam teknik klasterisasi, yaitu *K-Means*, *DBSCAN*, dan *Hierarchical Clustering*. Di antara metode tersebut, *K-Means* merupakan yang paling sering digunakan karena kesederhanaannya dalam implementasi [9]. Namun, *K-Means* memerlukan jumlah klaster ( $k$ ) untuk ditentukan terlebih dahulu, yang jika tidak sesuai dengan struktur data, dapat menyebabkan hasil klasterisasi yang kurang optimal. Oleh karena itu, terdapat metode yang serupa dengan *K-Means*, yaitu *X-Means*. Metode *X-Means* adalah

pengembangan dari *K-Means* yang menambahkan metrik evaluasi internal untuk menentukan jumlah kluster yang optimal, selain itu dapat menghasilkan kluster dengan proses komputasi yang lebih cepat dibandingkan dengan *K-Means* [10].

Metode *X-Means* dikembangkan oleh Dan Pelleg dan Andrew Moore pada tahun 2000 sebagai algoritma perbaikan dari *K-Means* [11]. *X-Means* menambahkan langkah eksplorasi kluster untuk menemukan jumlah kluster yang optimal, sehingga lebih fleksibel dalam menghadapi data yang kompleks [12]. Proses pembentukan kluster dengan metode *X-Means* dimulai dari kluster terkecil dengan minimum kluster dua dan dua kluster yang terbentuk tersebut, masing-masing akan dilakukan perhitungan dengan kriteria *Bayesian Information Criterion* (BIC). Penggunaan metode ini dalam klasterisasi pelanggan berdasarkan pola pembayaran diharapkan memberikan dampak bagi perusahaan dan dapat menghasilkan analisis data yang informatif sehingga dapat membuat strategi perusahaan yang tepat [13].

Adapula beberapa penelitian terdahulu yang serupa, penelitian yang dilakukan oleh Yusuf dkk berfokus pada analisis segmentasi terhadap data kemiskinan di Provinsi Aceh yang menggunakan dua algoritma klasterisasi. Membandingkan algoritma *K-Means* dan *X-Means* dalam segmentasi data kemiskinan di Provinsi Aceh, dengan hasil keduanya memiliki kualitas klasterisasi baik (*Silhouette Score* 0,89 dan 0,88; DBI 0,16). Namun, *X-Means* lebih unggul karena mampu menentukan jumlah kluster secara otomatis, menghasilkan efisiensi waktu komputasi lebih cepat, serta cocok untuk data berskala besar dan tidak seimbang. [10].

Penelitian dari Sulistio, dkk. menerapkan algoritma *X-Means* untuk mengelompokkan data penjualan barang di Transmart dengan tujuan mengidentifikasi produk yang paling potensial dan kurang potensial untuk mendukung strategi pemasaran perusahaan. Hasil klasterisasi menunjukkan bahwa nilai optimal  $k$  adalah 2, dengan evaluasi menggunakan *Davies-Bouldin Index* (DBI) sebesar 0,574, di mana hasil terbaik diperoleh tanpa menggunakan normalisasi. Penelitian ini membuktikan bahwa *X-Means* mampu mengelompokkan produk secara efektif berdasarkan perilaku penjualan dan

memberikan rekomendasi yang bermanfaat untuk manajemen persediaan dan perencanaan strategi penjualan [14].

Penelitian berikutnya dilakukan oleh Depari, G. meneliti segmentasi properti dengan membandingkan *K-Means*, *X-Means*, dan *K-Medoids* untuk pengelompokan karakteristik rumah terjual dalam penentuan harga. Hasilnya menunjukkan tiga kluster, dengan kluster 0 memiliki akurasi 85,77% pada harga rumah rendah, serta kinerja *K-Means* dan *X-Means* yang mirip, namun *X-Means* lebih unggul karena mampu menentukan jumlah kluster secara otomatis. [15].

Selanjutnya Adhitama, dkk menerapkan *X-Means Clustering* pada 27.574 data UMKM di Banyumas berdasarkan omset, aset, dan tenaga kerja, menghasilkan tiga kluster utama dengan purity 0,9892. Hasil terbaik diperoleh pada lima kluster (purity 0,9928), dan metode ini terbukti efektif untuk merekomendasikan jenis usaha potensial yang adaptif di masa krisis. [16].

Nurelasari, meneliti segmentasi perilaku pembayaran pelanggan multimedia menggunakan *K-Means* dan C4.5 untuk memprediksi kelayakan pelanggan pascabayar. Hasilnya, segmentasi awal dengan *K-Means* meningkatkan akurasi klasifikasi dari 59,02% menjadi 77,31% serta AUC dari 0,537 menjadi 0,836, menunjukkan efektivitas segmentasi dalam prediksi risiko gagal bayar. [17]

Berdasarkan dari beberapa penelitian di atas, menunjukkan bahwa metode *X-Means* adalah metode yang memberikan fleksibilitas dan efisien berdasar dengan apa yang dihasilkan oleh penelitian yusuf, dkk. Namun, penelitian terdahulu lebih banyak berfokus pada kemiskinan, UMKM, belum ada yang secara spesifik membahas pola pembayaran pelanggan properti yang berdampak langsung pada arus kas perusahaan. Oleh karena itu, penelitian ini mencoba menggunakan metode *X-Means* untuk mengelompokkan data pola pembayaran pelanggan properti. Sebagai kebaruan, penelitian ini juga memanfaatkan streamlit sebagai tampilan *user interface* untuk memvisualisasikan hasil klasterisasi. Pemilihan Streamlit didasarkan pada keunggulannya dalam menyajikan visualisasi data yang interaktif, mudah digunakan, dan dapat langsung dimanfaatkan oleh pihak manajemen tanpa perlu pemahaman teknis pemrograman. Diharapkan hasil segmentasi ini dapat membantu perusahaan dalam menyusun strategi komunikasi, pelayanan,

pengambilan keputusan tepat sasaran dan mendukung keberlangsungan operasional berkelanjutan.

### 1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, berikut merupakan rumusan masalah dalam penelitian ini:

1. Bagaimana mengidentifikasi permasalahan bisnis terkait keterlambatan pembayaran pelanggan dan risiko arus kas perusahaan?
2. Bagaimana memperoleh dan memastikan relevansi data historis pembayaran pelanggan untuk penelitian?
3. Bagaimana proses *preprocessing* dilakukan agar data pembayaran pelanggan sesuai dengan kebutuhan analisis *Clustering*?
4. Bagaimana penerapan metode *X-Means* dalam melakukan segmentasi pelanggan berdasarkan pola pembayaran?
5. Bagaimana mengevaluasi kualitas klaster yang terbentuk melalui metode *X-Means*?
6. Bagaimana interpretasi hasil segmentasi pelanggan berdasarkan pola pembayaran yang terbentuk melalui penerapan metode *X-Means*?

### 1.3. Batasan Masalah

Batasan-batasan masalah dari penelitian ini yaitu;

1. Penelitian ini hanya menggunakan data transaksi pembayaran pelanggan yang diperoleh dari perusahaan properti PT XYZ sebagai sumber data tunggal.
2. Data yang digunakan terbatas pada periode Januari 2019 hingga November 2024.
3. Penelitian ini hanya berfokus pada penerapan metode klusterisasi *X-Means* dalam proses segmentasi pelanggan berdasarkan pola pembayaran.
4. Fitur yang digunakan dalam segmentasi terbatas hanya pada fitur yang berkaitan dengan riwayat pembayaran.

#### 1.4. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dijelaskan, tujuan penelitian ini adalah melakukan segmentasi pelanggan properti pada PT XYZ berdasarkan pola pembayaran. Adapun rincian tujuan penelitian ini sebagai berikut:

1. Mengidentifikasi permasalahan bisnis terkait keterlambatan pembayaran pelanggan serta dampaknya terhadap risiko arus kas perusahaan.
2. Memperoleh dan memastikan relevansi data historis pembayaran pelanggan yang digunakan dalam penelitian.
3. Melakukan preprocessing pada data pembayaran pelanggan agar sesuai dengan kebutuhan analisis *Clustering*.
4. Menerapkan metode *X-Means* untuk melakukan segmentasi pelanggan berdasarkan pola pembayaran.
5. Mengevaluasi kualitas klaster yang terbentuk melalui penerapan metode *X-Means*.
6. Menginterpretasikan hasil segmentasi pelanggan berdasarkan pola pembayaran untuk mendukung pengambilan keputusan bisnis.

#### 1.5. Manfaat Penelitian

Penelitian ini diharapkan mampu memberikan manfaat-manfaat bagi pihak-pihak yang membutuhkan:

##### 1) Manfaat Teoritis

Penelitian ini diharapkan memberikan kontribusi dalam analisis data dan segmentasi pelanggan di industri properti. Dengan pendekatan analitik, penelitian ini membantu memahami pola pembayaran dan perilaku pelanggan secara komprehensif. Hasilnya dapat menjadi referensi bagi peneliti dan perusahaan dalam merumuskan strategi pemasaran yang tepat, mengelola risiko finansial, serta meningkatkan retensi dan loyalitas pelanggan bernilai tinggi.

##### 2) Manfaat Praktis

- a. Bagi penulis, penelitian ini menjadi sarana untuk memperluas wawasan dalam penerapan machine learning, khususnya algoritma *X-Means* untuk segmentasi pola pembayaran. Penelitian ini juga memberikan



pengalaman praktis dalam pemodelan data, pemilihan fitur, dan analisis klaster, serta menjadi langkah awal dalam mengasah kompetensi di bidang analisis data.

- b. Bagi peneliti berikutnya, penelitian ini diharapkan memberikan kontribusi bagi peneliti selanjutnya dalam merancang studi yang sejalan di bidang serupa. Temuan dan wawasan dari penelitian ini dapat menjadi landasan untuk mengembangkan ide baru, memperdalam analisis, serta menerapkan metodologi yang terbukti efektif.
- c. Bagi perusahaan, penelitian ini diharapkan mendukung pengambilan keputusan yang lebih strategis melalui pemahaman mendalam terhadap karakteristik pelanggan. Hasil klasterisasi dapat digunakan untuk merancang strategi pemasaran yang tepat, menyesuaikan produk, meningkatkan layanan, serta membantu alokasi sumber daya, identifikasi peluang pasar, dan mitigasi risiko, sehingga menjadi alat bantu yang relevan dalam mencapai tujuan bisnis.

*Halaman ini sengaja dikosongkan*

## BAB II

### TINJAUAN PUSTAKA

#### 2.1 Penelitian Terdahulu

Penelitian terdahulu digunakan sebagai acuan dalam mengembangkan landasan konseptual dan metodologi dalam penelitian ini. Berikut beberapa penelitian terdahulu yang dirangkum pada Tabel 2.1.

**Tabel 2.1.** Tabel Penelitian Terdahulu

| No | Profil Pustaka                                                                                                                                                                                                                                                                                                                         | Metode dan Temuan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
|----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | <p><b>Judul:</b><br/>Segmentasi Dan Klasifikasi Perilaku Pembayaran Pelanggan Pada Perusahaan Multimedia Dengan Algoritma <i>K-Means</i> Dan C4.5</p> <p><b>Penulis:</b><br/>1. Nurelasari, E.</p> <p><b>Identitas artikel:</b><br/>Jurnal Komputer dan Informatika Universitas Bina Sarana Informatika, Vol. XXI No. 1 Maret 2019</p> | <p><b>Metode:</b><br/>Penelitian mengenai segmentasi perilaku pembayaran pelanggan pada Perusahaan multimedia yang menggunakan metode <i>K-Means</i> dan C4.5. Pada penelitian terkait, metode C4.5 menjadi salah satu algoritma favorit untuk digunakan dalam mengklastering kebangkrutan nasabah dan mampu menghasilkan model dengan akurasi tinggi, serta mudah dipahami.</p> <p><b>Temuan:</b><br/>Hasil dari penelitian ini mencapai akurasi dari 59,02% menjadi 77,31% dan AUC dari 0,537 menjadi 0,836.</p> |
| 2  | <p><b>Judul:</b><br/>Analisis <i>Clustering</i> Penduduk Miskin di Provinsi Aceh Menggunakan Algoritma <i>K-Means</i> dan <i>X-Means</i></p> <p><b>Penulis:</b><br/>1. Bustmi Yusuf</p>                                                                                                                                                | <p><b>Metode:</b><br/>Penelitian ini berfokus pada analisis segmentasi terhadap data kemiskinan di Provinsi Aceh tahun 2018 menggunakan dua algoritma klasterisasi, yaitu <i>K-Means</i> dan <i>X-Means</i>. Tujuan penelitian ini adalah untuk membandingkan performa kedua algoritma.</p>                                                                                                                                                                                                                        |

| No | Profil Pustaka                                                                                                                                                                                  | Metode dan Temuan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|----|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    | <p>2. Rike Mahara<br/>3. Hendri Ahmadian<br/>4. Sri Wahyuni<br/>5. Khairan AR</p> <p><b>Identitas artikel:</b><br/>Jurnal Nasional Komputasi dan Teknologi Informasi, Vol 5 No 1 Tahun 2022</p> | <p><b>Temuan:</b><br/>Pengujian pada data menunjukkan bahwa kedua algoritma memiliki hasil klasterisasi yang baik dengan masing-masing metode mendapatkan nilai <i>K-Means</i> sebesar 0.89 dan <i>X-Means</i> sebesar 0.88 serta <i>Davies-Bouldin Index</i> (DBI) yang sama-sama 0.16. Namun, <i>X-Means</i> menunjukkan keunggulan dalam waktu komputasi yang lebih cepat yaitu 0.06 detik dibandingkan 0.22 detik pada <i>K-Means</i>. Hasil klasterisasi menunjukkan bahwa <i>K-Means</i> dan <i>X-Means</i> menghasilkan pengelompokan kategori kemiskinan yang berbeda. <i>K-Means</i> mengelompokkan data ke dalam kategori Sangat Miskin, Miskin, Rentan Miskin, dan Tidak Miskin pada klaster 0 hingga 3, sedangkan <i>X-Means</i> menghasilkan urutan kategori yang berbeda dengan efisiensi iterasi yang lebih tinggi. Hasil ini menunjukkan bahwa <i>X-Means</i> mampu mengidentifikasi struktur klaster secara otomatis dan efisien, menjadikannya cocok untuk segmentasi data berskala besar dan tidak seimbang.</p> |
| 3  | <p><b>Judul:</b><br/>Analisis Rumah Tidak Layak Huni Menggunakan Algoritma <i>X-Means</i></p> <p><b>Penulis:</b><br/>1. Ghina Fitria Rohendi<br/>2. Nana Suarna<br/>3. Gifthera Dwi Lestari</p> | <p><b>Metode:</b><br/>Penelitian ini penulis mengelompokkan rumah yang tidak layak dihuni yang dilihat dari bentuk bangunan dan fasilitas rumah di wilayah Batu layang, siantan hilir, siantan Tengah dan hulu. Metode yang digunakan pada penelitian ini adalah <i>X-Means Clustering</i> dengan dua tahap yang dilakukan berulang hingga selesai. Tahapan pertama meningkatkan Params, proses</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                 |

| No | Profil Pustaka                                                                                                                                     | Metode dan Temuan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|----|----------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    | <p><b>Identitas artikel:</b><br/>Jurnal Janitra Informatika dan Sistem Informasi Vol. 3 No. 1 Hal. 18-29, April 2023</p>                           | <p>ini menerapkan algoritma <i>K-Means</i> untuk awal penentuan k klaster hingga kestabilan atau optimal. Tahapan kedua adalah perbaikan struktur, tahapan ini dilakukan dengan memecah setiap klaster menjadi dua anak dalam arah yang berlawanan di sepanjang vektor yang dipilih secara acak. Penelitian ini bertujuan untuk menggali informasi dalam memetakan atau mengelompokkan rumah tidak layak huni menggunakan algoritma <i>X-Means</i> menjadi beberapa cluster serta untuk mengetahui nilai akurasi terbaik dari hasil uji <i>Davies Bouldin Index</i> (DBI)</p> <p><b>Temuan:</b><br/>Hasil pengelompokan menunjukkan bahwa model optimal terbentuk dalam dua klaster, yaitu klaster 0 dengan 931 rumah dan klaster 1 dengan 444 rumah. Algoritma <i>X-Means</i> menghasilkan nilai DBI sebesar 2,079. Selain itu, dengan menghitung jarak rata-rata antar klaster, ditemukan bahwa klaster 0 adalah kelompok terbaik, dengan jarak terdekat sebesar 9,728. Dari enelitian ini metode <i>X-Means</i> mendapatkan klaster yang optimal dan terbaikDari enelitian ini metode <i>X-Means</i> mendapatkan klaster yang optimal dan terbaik</p> |
| 4  | <p><b>Judul:</b><br/>Penerapan X Means <i>Clustering</i> Pada UMKM Kab Banyumas Yang Mendukung Mega Shifting Consumer Behavior Akibat Covid-19</p> | <p><b>Metode:</b><br/>Menggunakan algoritma <i>X-Means Clustering</i> untuk mengelompokkan 27.574 data UMKM di Kabupaten Banyumas. Variabel yang digunakan dalam proses klasterisasi meliputi omset tahunan, jumlah aset, dan jumlah tenaga</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |

| No | Profil Pustaka                                                                                                                                                                                                                                                                                                                               | Metode dan Temuan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|----|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    | <p><b>Penulis:</b></p> <ol style="list-style-type: none"> <li>1. Rifki Adhitama</li> <li>2. Auliya Burhanuddin</li> <li>3. Atik Febriani</li> </ol> <p><b>Identitas artikel:</b><br/>Journal of Informatics, Information System, Software Engineering and Applications Vol.4(1), Hal. 071-080, Nov 2021</p>                                  | <p>kerja. Penelitian ini juga mengeksplorasi kualitas klasterisasi dengan membandingkan hasil dari 3 hingga 6 klaster menggunakan metrik purity.</p> <p><b>Temuan:</b><br/>Hasil penelitian menunjukkan bahwa <i>X-Means</i> berhasil membentuk tiga kelompok utama UMKM, yaitu besar (58), sedang (381), dan kecil (26.602). Nilai purity tertinggi mencapai 0,9928 pada pengelompokan lima klaster, menunjukkan kualitas klasterisasi yang sangat baik. Selain itu, penelitian ini memberikan rekomendasi jenis usaha potensial yang tangguh di tengah krisis, seperti kuliner, bengkel, pertanian, dan warung sembako.</p>                                                                                                                            |
| 5  | <p><b>Judul:</b><br/>Real Estate Segmentation: A Model of Real Estate Decision Support System</p> <p><b>Penulis:</b></p> <ol style="list-style-type: none"> <li>1. Genesis Sembiring Depari</li> </ol> <p><b>Identitas artikel:</b><br/>Sang Pencerah: Jurnal Ilmiah Universitas Muhammadiyah Buton Vol 7 No. 2 Hal. 233-250, Tahun 2021</p> | <p><b>Metode:</b><br/>Penelitian yang dilakukan oleh Depari, G. (2021) bertujuan untuk mengembangkan model segmentasi properti guna mendukung pengambilan keputusan manajemen di bidang real estate. Dalam studi ini, peneliti membandingkan performa tiga algoritma klasterisasi, yaitu <i>K-Means</i>, <i>X-Means</i>, dan <i>K-Medoids</i>, dalam mengelompokkan karakteristik rumah yang telah terjual. Tujuan segmentasi ini adalah untuk menentukan estimasi harga rumah serta menyusun strategi pemasaran yang lebih terarah. Algoritma-algoritma tersebut diterapkan pada dataset yang berisi berbagai atribut properti, dan selanjutnya dibandingkan berdasarkan akurasi serta kemampuannya dalam menentukan jumlah klaster. <i>X-Means</i></p> |

| No | Profil Pustaka | Metode dan Temuan                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|----|----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|    |                | <p>digunakan untuk keunggulannya dalam menentukan jumlah klaster secara otomatis, sedangkan <i>K-Means</i> memerlukan tahapan tambahan untuk menentukan jumlah klaster optimal sebelum proses klasterisasi dilakukan.</p> <p><b>Temuan:</b></p> <p>Hasil dari penelitian menunjukkan bahwa algoritma <i>X-Means</i> dan <i>K-Means</i> memiliki kinerja yang sangat mirip dalam membentuk klaster. Namun, <i>X-Means</i> dinilai lebih praktis karena mampu menentukan jumlah klaster secara otomatis tanpa intervensi manual. Klasterisasi menghasilkan tiga kelompok utama, yaitu Klaster 0, Klaster 1, dan Klaster 2. Salah satu hasil signifikan adalah bahwa Klaster 0 memiliki akurasi sebesar 85,77% dalam mengidentifikasi rumah dengan harga jual rendah. Peneliti juga melakukan karakterisasi pada masing-masing klaster untuk mendukung strategi pemasaran berbasis data, dan menyimpulkan bahwa integrasi machine learning dalam manajemen properti dapat meningkatkan efektivitas analisis pasar dan perencanaan bisnis.</p> |

Penelitian ini memberikan pendekatan baru dalam segmentasi pelanggan pada industri properti, dengan fokus pada pola pembayaran pelanggan *PT XYZ*, serta penerapan algoritma *X-Means* dalam proses analisisnya. *User Interface* dikembangkan pula untuk mempermudah dalam menganalisis data. Berbeda dengan metode *K-Means* yang umum digunakan dalam segmentasi, penelitian ini menggunakan metode *X-Means*. Tidak seperti *K-Means* yang mengharuskan penentuan jumlah klaster di awal, *X-Means* mampu menentukan jumlah klaster optimal dengan menambahkan langkah eksplorasi didalam prosesnya, sehingga

lebih sesuai untuk data yang kompleks dan tidak terdistribusi secara merata. Hasil dari penelitian ini diharapkan dapat dimanfaatkan untuk merancang strategi komunikasi, pelayanan, dan pengambilan keputusan yang lebih tepat sasaran, guna mendukung keberlanjutan operasional perusahaan secara jangka panjang.

## **2.2 Dasar Teori**

### **2.2.1. Properti**

Properti merupakan salah satu sektor penting dalam perekonomian yang berkaitan dengan kepemilikan atas tanah, bangunan, atau aset tidak bergerak lainnya. Properti dapat diartikan sebagai aset yang dimiliki atau dikelola oleh individu maupun perusahaan untuk tujuan hunian, komersial, investasi, atau pengembangan jangka panjang. Menurut Undang-Undang Republik Indonesia Nomor 1 Tahun 2011 tentang Perumahan dan Kawasan Permukiman, properti mencakup seluruh kegiatan pembangunan, pemanfaatan, serta pemeliharaan bangunan dan lahan sebagai tempat tinggal dan kegiatan lainnya [18].

Perusahaan properti melibatkan berbagai jenis transaksi seperti jual beli rumah, apartemen, ruko, dan tanah kavling, baik secara tunai maupun angsuran. Sistem pembayaran angsuran inilah yang menjadi bagian penting dari aktivitas operasional perusahaan properti, karena berkaitan langsung dengan arus kas masuk dan stabilitas finansial perusahaan [6]. Oleh karena itu, memahami pola pembayaran pelanggan menjadi aspek strategis dalam pengelolaan usaha properti.

Seiring dengan meningkatnya persaingan di sektor ini dan fluktuasi daya beli masyarakat, perusahaan properti perlu mengembangkan sistem pengelolaan pelanggan yang lebih responsif dan berbasis data. Salah satunya adalah melalui analisis terhadap perilaku pembayaran pelanggan agar dapat diterapkan strategi penagihan, komunikasi, dan layanan purna jual yang lebih tepat sasaran. Pendekatan ini bertujuan untuk meminimalkan risiko keterlambatan pembayaran serta meningkatkan efisiensi dan profitabilitas jangka panjang.



### 2.2.2. *Inhouse* Syariah


Sistem *inhouse* syariah merujuk pada skema pembiayaan properti di mana developer atau perusahaan properti menyediakan fasilitas cicilan langsung kepada konsumen tanpa keterlibatan bank atau lembaga keuangan formal [19]. Dalam praktik ini, akad yang digunakan harus sesuai prinsip-prinsip syariah, yakni bebas dari riba (bunga), denda yang memberatkan, dan penyitaan tidak adil. Contohnya seperti penggunaan akad jual beli langsung atau akad seperti *Istishna'* yang menyesuaikan pembuatan properti berdasarkan pesanan tanpa melibatkan pihak ketiga sebagai pemberi pembiayaan.

Keuntungan utama dari skema *inhouse* syariah meliputi transparansi, keadilan, dan kepastian bagi pembeli karena pembayaran dan margin keuntungan ditetapkan sejak awal, serta fleksibilitas dalam hubungannya dengan risiko keterlambatan pembayaran. Selain itu, sistem ini juga dapat meningkatkan kepercayaan konsumen muslim yang mengutamakan kepatuhan terhadap syariah dalam aspek finansial. Namun, ada tantangan praktisnya, yaitu pengelolaan risiko menjadi lebih kompleks karena perusahaan tidak memiliki instrumen penalti seperti denda bunga, sehingga keterlambatan pembayaran memiliki dampak langsung terhadap arus kas [20]. Keterbatasan lainnya adalah regulasi yang belum selalu spesifik mengatur properti syariah tanpa bank, dan tingkat literasi konsumen terhadap akad-akad syariah ini kadang masih rendah.

### 2.2.3. Segmentasi

Segmentasi merupakan proses pembagian suatu populasi atau kumpulan entitas menjadi kelompok-kelompok yang lebih kecil berdasarkan karakteristik tertentu yang serupa di antara anggota dalam kelompok tersebut [21]. Dengan kata lain, segmentasi membantu mengelompokkan individu atau entitas yang memiliki atribut, perilaku, atau kebutuhan yang sama, sehingga lebih mudah dianalisis dan dikelola. Segmentasi pasar adalah kegiatan yang bertujuan untuk memecah pasar yang bersifat heterogen menjadi beberapa kelompok yang lebih homogen [22].

Pelanggan dianggap sebagai aset sebuah perusahaan karena berkontribusi pada pertumbuhan dan keberlanjutan sebuah bisnis. Melalui segmentasi, perusahaan dapat memprioritaskan sumber daya mereka pada kelompok pelanggan yang memiliki loyalitas tinggi atau potensi profitabilitas yang lebih besar. Selain itu, segmentasi juga memungkinkan perusahaan untuk merancang strategi pemasaran yang lebih personal, seperti program loyalitas atau promosi khusus, yang dapat meningkatkan kepuasan dan keterikatan pelanggan. Dengan demikian, segmentasi tidak hanya membantu meningkatkan efisiensi pemasaran tetapi juga memperkuat hubungan perusahaan dengan pelanggan, memastikan bahwa setiap kelompok mendapatkan layanan yang tepat. Proses ini menjadi landasan penting bagi perusahaan dalam menyusun strategi bisnis yang berorientasi pada konsumen dan dalam menghadapi persaingan pasar yang semakin kompleks.



**Gambar 2.1.** Ilustrasi Segementasi Pelanggan[23]

Tujuan segmentasi adalah untuk memahami perbedaan di antara kelompok-kelompok tersebut sehingga perusahaan dapat menyusun strategi yang lebih efektif, misalnya dalam pemasaran, pengembangan produk, atau pelayanan pelanggan. Ada beberapa jenis segmentasi yang umum digunakan, tergantung pada karakteristik yang menjadi dasar pembagian:

- a. Segmentasi Demografis, pengelompokkan berdasarkan karakteristik seperti usia, jenis kelamin, pendapatan, pekerjaan, pendidikan, atau status perkawinan.
- b. Segmentasi Geografis, pengelompokkan pasar berdasarkan lokasi geografis, seperti negara, kota, daerah, atau bahkan lingkungan. Ini relevan


jika preferensi atau perilaku pelanggan bervariasi berdasarkan wilayah tempat tinggal mereka.

- c. Segmentasi Psikografis, mengelompokkan berdasarkan aspek psikologis seperti gaya hidup, kepribadian, nilai-nilai, atau minat. Segmentasi ini lebih kompleks karena berfokus pada aspek emosional atau persepsi yang mempengaruhi perilaku pembelian.
- d. Segmentasi Perilaku, berdasarkan perilaku pelanggan, seperti kebiasaan pembelian, frekuensi penggunaan produk, loyalitas terhadap merek, atau tingkat keterlibatan dengan produk. Segmentasi perilaku biasanya digunakan untuk memahami pelanggan berdasarkan tindakan mereka yang terlihat.

Dengan mengenali kelompok pelanggan, strategi pemasaran dapat dirancang untuk lebih sesuai dengan preferensi dan kebutuhan segmen tertentu, sehingga meningkatkan peluang sukses kampanye pemasaran, memahami kebutuhan dan keinginan segmen pelanggan, perusahaan dapat menciptakan produk atau layanan yang lebih relevan dan menarik bagi mereka. Jika suatu perusahaan berfokus pada segmen yang tepat, perusahaan dapat mengalokasikan sumber daya dengan lebih efisien, baik dalam hal promosi, distribusi, maupun pengembangan produk. Ketika perusahaan mampu menyediakan produk dan layanan yang sesuai dengan kebutuhan segmen pelanggan tertentu, tingkat kepuasan dan loyalitas pelanggan akan meningkat.

#### 2.2.4. Klasterisasi

Klasterisasi adalah sekumpulan objek yang memiliki karakteristik atau kesamaan tertentu. Klasterisasi merupakan metode *machine learning* tanpa perlu label atau kategori pada datanya (*unsupervised learning*), yang bertujuan untuk mengelompokkan objek-objek serupa ke dalam satu kelompok.



**Gambar 2.2.** Ilustrasi *Clustering*[24]

Metode ini berbeda dengan klasifikasi dan regresi, di mana setiap data sudah memiliki label yang ditentukan secara manual. Dengan klasterisasi, dapat membuat model yang mampu mengelompokkan pelanggan berdasarkan kemiripan atribut tertentu. Misalnya, 80% pelanggan toko *online* tersebut adalah perempuan, dan 20% sisanya adalah laki-laki. Dari kelompok perempuan, 60% cenderung berbelanja pada hari kerja, sementara sisanya berbelanja di akhir pekan. Dalam contoh lain, 40% pelanggan berasal dari Pulau Jawa, 55% dari luar Pulau Jawa, dan 5% lainnya dari luar negeri. Dengan melakukan klasterisasi berdasarkan pola-pola tertentu, kita dapat menganalisis target pasar yang sesuai untuk setiap kelompok pelanggan.

#### 2.2.5. *K-Means*

*K-Means* merupakan algoritma *Clustering* dirancang dengan dasar konsep *centroid*. Proses *Clustering* dilakukan dengan menghitung jarak antara setiap data dan *centroid* yang mewakili pusat kluster. Setiap data diletakkan ke dalam pusat kluster terdekat. Tujuan dari algoritma ini adalah untuk menemukan berapa banyak  $k$  atau kelompok yang terbentuk dalam suatu dataset. Berikut adalah cara kerja dari algoritma *K-Means*;

1. Menentukan jumlah  $k$ , memisalkan nilai *centroid* sebanyak  $k$  yang ditentukan,

2. Menghitung jarak setiap data ke permisalan *centroid* yang sudah ditentukan. Perhitungan jarak data ke *centroid* menggunakan rumus *Euclidean*. Data akan dimasukkan ke dalam *centroid* yang paling dekat. Berikut adalah rumus dari perhitungan *Euclidean*:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2 \quad (2.1)$$

Di mana:

- $k$  : jumlah klaster
  - $C_i$  : himpunan data diklaster  $i$
  - $x$  : Vektor data
  - $\mu_i$  : *centroid* klaster  $i$
3. Memperbarui nilai *centroid* yang diperoleh dari rata-rata jumlah anggota klaster dengan rumus:

$$C_{m(q)} = \frac{1}{n_m} \sum_{i=1}^{n_m} x_{i(q)} \quad (2.2)$$

Di mana:

- $C_{m(q)}$  : *Centroid* dari klaster  $m$  pada perhitungan ke  $q$
  - $n_m$  : Banyaknya data pada klaster  $m$
  - $x_{i(q)}$  : Data ke  $i$  pada iterasi ke  $q$
4. Melakukan perulangan dari tahapan 3 dan 4 hingga anggota tiap klaster tidak ada yang berubah.

#### 2.2.6. *X-Means*

*X-Means* adalah algoritma pengembangan dari *K-Means Clustering*, dirancang untuk mengatasi beberapa keterbatasan mendasar dari *K-Means*, khususnya dalam menentukan jumlah klaster optimal. *K-Means Clustering* adalah algoritma *Clustering* yang sering digunakan, berfungsi untuk mengelompokkan data ke dalam sejumlah klaster " $k$ ". Namun, kelemahan utama dari algoritma ini adalah perlunya menentukan jumlah klaster ( $k$ ) terlebih dahulu, yang seringkali sulit diprediksi di awal analisis. Untuk mengatasi keterbatasan ini, *X-Means* dikembangkan oleh Dan Pelleg dan Andrew Moore pada tahun 2000 sebagai perbaikan dari *K-Means* [11]. Algoritma *X-Means* menambahkan langkah eksplorasi klaster untuk secara otomatis menemukan jumlah klaster yang optimal hingga mencapai  $k$

maksimal yang telah ditentukan, sehingga memberikan fleksibilitas dalam data yang kompleks. Proses *X-Means* dapat dirangkum dalam beberapa langkah:

1. Algoritma dimulai dengan menginisialisasi *K-Means*, menggunakan jumlah kluster awal biasanya 2.
2. Setiap kluster yang terbentuk diperhitungkan menggunakan *Bayesian Information Criterion (BIC)*. BIC digunakan untuk menghitung pembagian kluster. Jika pemisahan suatu kluster menghasilkan peningkatan nilai BIC, kluster tersebut akan dibagi; jika tidak, kluster dibiarkan tetap utuh. Proses ini berlanjut secara iteratif hingga semua kluster mencapai konfigurasi optimal, di mana tidak ada lagi kluster yang perlu dibagi lebih lanjut. Rumus BIC adalah sebagai berikut:

$$BIC = L - \frac{p}{2} \log N \quad (2.3)$$

Di mana:

- $L$  : nilai *log likelihood* dari model (seberapa baik model menjelaskan data).
- $p$  : jumlah parameter dalam model (jumlah kluster dan fitur).
- $N$  : jumlah data.

Jika BIC meningkat ketika kluster dibagi, maka pembagian tersebut dianggap sah. Jika tidak, pembagian kluster tidak dilakukan. Ada beberapa tahapan untuk mendapatkan nilai *log likelihood*. Berikut rumus untuk mendapatkan nilai *log likelihood*:

$$L = -\frac{n}{2} \log(2\pi) - \frac{n \cdot d}{2} \log(\sigma^2) - \frac{1}{2\sigma} r \sum_{i=1}^n \|x_i - \mu\|^2 \quad (2.4)$$

Dengan:

- $d$ : Jumlah dimensi fitur
- $\sigma^2$ : variansi dalam kluster (diasumsikan sama di semua dimensi)
- $\mu$ : *centroid* kluster
- $\|x_i - \mu\|^2$ : jarak kuadrat data ke *centroid*

Dan untuk mendapatkan variansi bisa menghitung dengan rumus:

$$\sigma^2 = \frac{SSE}{n} \quad (2.5)$$

Dengan:

- $SSE$ : Total error kuadrat dari semua titik ke *centroid*
- $n$ : Jumlah titik dalam kluster

### 2.2.7. *RobustScaler*

*RobustScaler* adalah salah satu teknik penskalaan data dalam modul *sklearn.preprocessing* yang digunakan untuk mengatasi masalah *outlier* dalam proses standarisasi[25]. Berbeda dengan *StandardScaler* yang bergantung pada nilai rata-rata (*mean*) dan standar deviasi sebagai dasar transformasi, *RobustScaler* menggunakan nilai median dan *interquartile range* (IQR), yaitu selisih antara kuartil ketiga (Q3) dan kuartil pertama (Q1). Pendekatan ini membuat *RobustScaler* lebih tahan terhadap pengaruh *outlier* yang dapat menyebabkan distribusi data menjadi bias atau tidak representatif [26]. Standarisasi dengan *RobustScaler* dilakukan menggunakan rumus sebagai berikut:

$$x' = \frac{x - \text{median}}{IQR} \quad (2.6)$$

Dengan:

$$IQR = Q3 - Q1 \quad (2.7)$$

Dimana  $x$  merupakan nilai asli dari data, median adalah nilai tengah dari distribusi, dan IQR adalah selisih antara kuartil ketiga dan kuartil pertama. Nilai hasil standarisasi  $x'$  akan menunjukkan seberapa jauh suatu data dari median jika diukur dalam satuan IQR [27]. Dengan demikian, metode ini cocok diterapkan pada dataset yang memiliki sebaran tidak normal atau mengandung *outlier*, karena tidak terpengaruh secara signifikan oleh penyimpangan nilai ekstrim.

Dalam penelitian ini, penggunaan *RobustScaler* dianggap tepat karena beberapa fitur numerik seperti Jumlah Transaksi, Selisih, dan Total Pembayaran memiliki rentang nilai yang cukup lebar serta mengandung *outlier*. Jika data tersebut tidak ditransformasi dengan metode yang sesuai, nilai-nilai ekstrem tersebut dapat mendominasi proses klusterisasi dan menyamarkan pola yang sebenarnya ingin diungkap. Dengan menerapkan

*RobustScaler*, data dinormalisasi menggunakan median dan *interquartile range* (IQR), sehingga pengaruh nilai ekstrem dapat diminimalkan, dan hasil klasterisasi menjadi lebih akurat dan representatif terhadap struktur data yang ada.

#### 2.2.8. *Silhouette Score*

*Silhouette Score* merupakan salah satu metrik evaluasi yang digunakan untuk mengukur kualitas hasil klasterisasi secara objektif tanpa memerlukan label atau *ground truth* [28]. Metrik ini menilai sejauh mana objek dalam satu klaster memiliki kemiripan satu sama lain, serta seberapa besar perbedaannya dengan objek-objek yang berada pada klaster lain.

Nilai *Silhouette Score* dihitung untuk setiap titik data dan berada dalam rentang antara -1 hingga 1 [29]. Semakin tinggi nilai *Silhouette Score* mendekati 1, maka semakin baik kualitas klasterisasi tersebut, karena objek-objek dalam klaster memiliki kesamaan tinggi dan berbeda secara signifikan dengan objek dari klaster lain. Sebaliknya, nilai mendekati 0 menunjukkan bahwa objek berada di batas antara dua klaster, dan nilai negatif menunjukkan bahwa objek lebih dekat ke klaster lain dibandingkan klasternya sendiri, yang menandakan kesalahan dalam pengelompokan. Perhitungan *Silhouette Score* didasarkan pada dua komponen utama, yaitu:

- a)  $a(i)$ : rata-rata jarak antara data  $i$  dan semua titik lain dalam klaster yang sama (disebut *cohesion*),
- b)  $b(i)$ : rata-rata jarak antara data  $i$  dan semua titik pada klaster terdekat lainnya (disebut *separation*).

Dengan dua nilai tersebut, skor *silhouette*  $s(i)$  untuk data ke- $i$  dihitung menggunakan rumus sebagai berikut:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (2.8)$$

Nilai rata-rata dari seluruh  $s(i)$  untuk semua titik data dalam dataset digunakan sebagai indikator umum dari kualitas klasterisasi. *Silhouette Score* sering digunakan untuk mengevaluasi hasil klasterisasi dengan jumlah klaster yang berbeda guna memilih jumlah klaster yang optimal [30].



Dalam penelitian ini, *Silhouette Score* dimanfaatkan sebagai metrik evaluasi untuk menilai kualitas segmentasi yang dihasilkan oleh *X-Means*. Meskipun *Silhouette Score* merupakan salah satu metrik evaluasi yang umum digunakan, hasilnya tetap perlu dianalisis bersama dengan visualisasi dan pemahaman terhadap data.

#### 2.2.9. Davies Bouldin Index (DBI)

*Davies-Bouldin Index* (DBI) merupakan salah satu metode evaluasi internal yang digunakan untuk menilai kualitas hasil klasterisasi tanpa memerlukan label data [31]. Indeks ini mengukur sejauh mana klaster-klaster yang terbentuk memiliki kompaksi (*tightness*) yang tinggi di dalam klaster dan separasi (*separation*) yang baik antar klaster. DBI memberikan nilai rata-rata dari rasio kesamaan antara satu klaster dengan klaster lainnya, di mana rasio tersebut mempertimbangkan jarak antar pusat klaster (*centroid*) dan sebaran (*dispersion*) masing-masing klaster [32]. Semakin rendah nilai DBI, semakin baik hasil klasterisasi yang dihasilkan karena menunjukkan klaster yang lebih kompak dan saling terpisah dengan jelas. Secara formal, *Davies-Bouldin Index* dihitung dengan menggunakan rumus berikut:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max \left( \frac{s_i + s_j}{M_{ij}} \right) \quad (2.9)$$

Dengan:

- a)  $k$  adalah jumlah klaster,
- b)  $s_i$  dan  $s_j$  adalah rata-rata jarak antara setiap titik data dalam klaster  $i$  dan  $j$  terhadap pusat klasternya,
- c)  $M_{ij}$  adalah jarak antara pusat klaster  $i$  dan  $j$ ,
- d) Nilai  $\frac{s_i + s_j}{M_{ij}}$  adalah menunjukkan rasio kemiripan antara klaster  $i$  dan  $j$ , dan nilai maksimum dari rasio kemiripan antara klaster  $i$  akan digunakan dalam perhitungan DBI.

Nilai DBI yang ideal mendekati nol, karena menunjukkan bahwa klaster-klaster saling terpisah dengan baik dan memiliki penyebaran data yang kecil di dalam masing-masing klaster. DBI sering digunakan sebagai salah satu kriteria seleksi model dalam pemilihan jumlah klaster yang optimal, terutama dalam

algoritma seperti *K-Means* atau *X-Means*. Evaluasi ini menjadi penting dalam konteks penelitian yang berfokus pada segmentasi pelanggan, karena hasil klaster yang representatif dapat membantu pengambilan keputusan bisnis yang lebih tepat sasaran.

#### 2.2.10. Calinski Harabasz

*Calinski-Harabasz Index* (CHI), juga dikenal sebagai *Variance Ratio Criterion*, merupakan salah satu metrik evaluasi internal yang digunakan untuk menilai kualitas hasil klasterisasi [33]. Indeks ini mengukur seberapa baik klaster yang terbentuk dalam memisahkan data menjadi kelompok yang homogen secara internal dan heterogen antar kelompok. Indeks ini didasarkan pada rasio antara dispersi antar-klaster (*between-cluster dispersion*) dengan dispersi dalam klaster (*within-cluster dispersion*)[34]. Semakin tinggi nilai indeks ini, maka semakin baik hasil klasterisasi yang terbentuk, karena menunjukkan bahwa klaster memiliki konsistensi internal yang kuat dan saling terpisah secara signifikan. Rumus *Calinski-Harabasz Index* dituliskan sebagai berikut:

$$CH = \frac{Tr(B_k)}{Tr(W_k)} \times \frac{n-k}{k-1} \quad (2.10)$$

Di mana:

- a)  $Tr(B_k)$  adalah *trace* atau jumlah diagonal dari matriks disperse antar klaster,
- b)  $Tr(W_k)$  adalah *trace* dari matriks disperse dalam klaster,
- c)  $n$  adalah jumlah total data,
- d)  $k$  adalah jumlah klaster.

Nilai CHI yang lebih tinggi menunjukkan bahwa klaster yang terbentuk memiliki pemisahan yang lebih jelas dan penyebaran data di dalam masing-masing klaster yang lebih kecil. Oleh karena itu, indeks ini sangat efektif digunakan untuk membandingkan hasil klasterisasi dari berbagai jumlah klaster atau algoritma, terutama pada dataset tanpa label. Dalam konteks segmentasi pelanggan, penggunaan *Calinski-Harabasz Index* memungkinkan peneliti untuk memilih model klasterisasi yang paling representatif terhadap

struktur data aktual, sehingga mendukung penyusunan strategi yang lebih akurat dan efisien dalam pengelolaan pelanggan.

*Halaman ini sengaja dikosongkan*

## BAB III

### DESAIN DAN IMPLEMENTASI SISTEM

#### 3.1 Variabel Penelitian dan Sumber Data

Dalam penelitian ini, jenis data yang digunakan adalah data sekunder, yaitu data yang diperoleh secara tidak langsung dari sumber aslinya melainkan telah dikumpulkan dan disediakan oleh pihak lain. Sumber data penelitian ini berasal dari PT XYZ, sebuah perusahaan yang bergerak di bidang properti dan pengembangan perumahan di wilayah Sidoarjo, Jawa Timur. PT XYZ merupakan pengembang yang aktif dalam membangun dan memasarkan unit rumah dan ruko sebagai bagian dari proyek perumahan komersial.

Data yang digunakan mencakup riwayat pembayaran angsuran dari pelanggan terhadap unit properti yang dibeli, baik berupa rumah maupun ruko, selama periode operasional antara tahun 2019 hingga 4 November 2024. Data tersebut terekam dalam bentuk *log* transaksi angsuran yang disimpan dalam sistem pencatatan perusahaan dan mencerminkan aktivitas pembayaran dari berbagai pelanggan terhadap unit-unit yang telah terjual. Secara keseluruhan, terdapat sebanyak 9.615 baris data transaksi yang terdokumentasi, yang masing-masing baris merepresentasikan satu entri pembayaran dalam periode tertentu.

Setiap baris data memiliki 7 kolom yang menggambarkan informasi penting terkait transaksi, seperti nomor unit properti, tanggal pembayaran, nominal pembayaran, serta status dari kewajiban pembayaran tersebut. Data ini menggambarkan dinamika pola pembayaran pelanggan secara historis dan dapat digunakan untuk mengidentifikasi pola pembayaran yang berbeda-beda, seperti ketepatan waktu pembayaran ataupun keterlambatan.

**Tabel 3.1.** Metadata


| Fitur            | Deskripsi                                  | Tipe Data     |
|------------------|--------------------------------------------|---------------|
| Nomor Unit       | ID unik unit properti                      | <i>String</i> |
| Jumlah Transaksi | Jumlah transaksi pembayaran yang dilakukan | <i>Int</i>    |
| Total Pembayaran | Total nominal pembayaran yang sudah masuk  | <i>Int</i>    |
| Harga            | Harga properti dari data master            | <i>Int</i>    |
| Selisih          | Selisih antara harga dan total pembayaran  | <i>Int</i>    |

| Fitur             | Deskripsi                       | Tipe Data     |
|-------------------|---------------------------------|---------------|
| Status Pembayaran | 1: Lunas, 0: Belum lunas        | <i>String</i> |
| Jumlah Terlambat  | Jumlah keterlambatan pembayaran | <i>Int</i>    |

Penjelasan lebih lanjut mengenai jenis masing-masing fitur disajikan pada Tabel 3.1, yang mencakup nama atribut, tipe data, dan deskripsi singkat tentang isi dari setiap fitur. Data ini digunakan sebagai dasar dalam proses pengolahan, eksplorasi, dan klasterisasi dalam penelitian untuk menghasilkan segmentasi pelanggan.

### 3.2. Langkah Analisis

Dalam melakukan penelitian segmentasi pola pembayaran pelanggan terdapat langkah-langkah analisis yang dicantumkan dalam bentuk diagram alir. Pada Gambar 3.1 ini adalah diagram alir dari penelitian ini:



**Gambar 3.1.** Diagram Alir Penelitian

Berdasarkan diagram alir pada Gambar 3.1, berikut merupakan penjelasan mengenai langkah-langkah yang dilakukan dalam penelitian ini, yaitu:

#### 3.2.1 Identifikasi Masalah

Identifikasi masalah merupakan langkah awal yang penting dalam proses penelitian, karena menjadi dasar dalam merumuskan arah dan tujuan

dari penelitian yang akan dilakukan. Tahapan ini dilakukan untuk mengenali serta memahami permasalahan nyata yang terjadi di lapangan, khususnya dalam konteks pengelolaan perilaku pembayaran pelanggan di industri properti. Permasalahan seperti keterlambatan pembayaran, pembayaran tidak penuh, hingga pelanggan yang menunggak, menjadi isu yang berdampak langsung terhadap kelancaran operasional dan kondisi keuangan perusahaan.

Setelah permasalahan tersebut diidentifikasi, selanjutnya dilakukan penelusuran terhadap studi dan pendekatan yang telah diterapkan dalam penelitian sebelumnya. Tujuannya adalah untuk memperluas pemahaman terhadap ruang lingkup permasalahan serta melihat sejauh mana metode-metode tertentu telah berhasil atau memiliki keterbatasan dalam menyelesaikan kasus serupa. Dalam konteks ini, penting untuk menilai efektivitas metode klasterisasi yang telah digunakan sebelumnya, seperti *K-Means*, dan mempertimbangkan potensi metode alternatif yang lebih adaptif seperti *X-Means*.

Dengan meninjau berbagai literatur dan penelitian terdahulu, dapat diketahui bahwa salah satu permasalahan utama dari metode konvensional adalah penentuan jumlah klaster yang belum tentu sesuai dengan struktur data. Oleh karena itu, penelitian ini mencoba menjawab permasalahan tersebut dengan menerapkan algoritma *X-Means* yang mampu menentukan jumlah klaster optimal dengan *range threshold* yang telah ditentukan, serta mengevaluasi hasilnya menggunakan metrik seperti *Silhouette Score*. Melalui tahapan identifikasi ini, diharapkan solusi yang dipilih dalam penelitian benar-benar relevan dan mampu memberikan hasil yang optimal.

### 3.2.2 Persiapan Data

Tahapan persiapan data merupakan langkah awal dalam proses analisis data, yang bertujuan untuk memastikan bahwa data yang digunakan telah bersih, lengkap, dan dalam format yang sesuai untuk dianalisis. Pada penelitian ini, proses persiapan data terdiri dari beberapa langkah utama yang dijelaskan sebagai berikut:

a. Membaca Data

Membaca data menjadi langkah pertama yang dilakukan dalam penelitian ini, pada tahap ini dilakukan membaca data mentah dari dua data yang akan digunakan, yaitu data transaksi pembayaran pelanggan dan data harga properti. Setelah data berhasil terbaca dilakukan tahapan selanjutnya dalam persiapan data.

b. Seleksi Data

Setelah data berhasil terbaca, dilakukan proses seleksi data, yang dimana pada tahap ini melakukan pemelihan fitur-fitur yang bisa dijadikan acuan untuk karakteristik setiap pelanggan seusia dengan tujuan penelitian.

c. *Missing Value*

Proses ini bertujuan untuk mendeteksi adanya nilai kosong atau hilang dalam dataset. Data yang memiliki *missing value* diperiksa dan ditandai, agar dapat ditangani pada tahap selanjutnya. Identifikasi nilai hilang penting untuk mencegah bias atau kesalahan dalam analisis berikutnya.

d. Konversi Tipe Data

Beberapa fitur dalam dataset awal masih berada dalam format non-numerik (seperti string atau kategori), yang tidak dapat langsung diolah dalam algoritma klusterisasi. Oleh karena itu, dilakukan konversi tipe data ke dalam format numerik. Misalnya, fitur “Status Pembayaran” yang awalnya berupa kategori “Lunas” dan “Belum Lunas” dikonversi menjadi bentuk numerik biner (1 dan 0).

e. Agregasi dan Penggabungan Data

Data transaksi yang bersifat granular (berdasarkan tanggal dan transaksi individual) perlu diagregasikan berdasarkan unit properti atau pelanggan. Agregasi ini menghasilkan representasi setiap pelanggan dalam satu baris data, dengan fitur-fitur seperti jumlah transaksi, total keterlambatan, dan



total pembayaran. Selanjutnya, data ini digabungkan dengan data harga unit untuk melengkapi informasi yang diperlukan.

*f. Final Missing Value*

Setelah data dikonversi dan digabungkan, dilakukan pengecekan akhir terhadap *missing value*. Nilai-nilai yang hilang diputuskan untuk diimputasi, dihapus, atau dibiarkan bergantung pada proporsi dan relevansinya. Tahapan ini memastikan bahwa dataset akhir yang digunakan untuk *preprocessing* dan analisis telah bersih dan siap untuk diproses lebih lanjut.

### 3.2.3 *Preprocessing Data*

Proses *data preprocessing* bertujuan untuk mempersiapkan data agar sesuai dengan kebutuhan algoritma klasterisasi yang akan digunakan. Tahapan ini mencakup transformasi data ke dalam format numerik dan proses standarisasi untuk menyamakan skala antar fitur. Dalam penelitian ini, *preprocessing* dilakukan melalui dua tahap utama, transformasi data dan standarisasi data.

a. Data Transformasi

Pada tahap transformasi, dilakukan pengubahan tipe data pada beberapa fitur agar sesuai dengan format yang dapat diproses oleh pustaka analisis Python. Fitur-fitur seperti Total Pembayaran, Harga, dan Selisih dikonversi menjadi tipe data *integer*, sedangkan fitur Nomor Unit dan Status Pembayaran dikonversi menjadi *string* untuk menghindari kesalahan tipe saat proses *encoding* dan analisis lebih lanjut.

Selanjutnya, fitur kategorikal Status Pembayaran yang sebelumnya memiliki dua label yakni “Lunas” dan “Belum Lunas” diubah ke dalam format numerik menggunakan teknik *binary encoding*. Dalam hal ini, nilai “Lunas” dikodekan sebagai 1, dan “Belum Lunas” sebagai 0. Konversi ini penting

karena algoritma klasterisasi seperti *X-Means* hanya dapat memproses data numerik.

b. Data Standarisasi

Setelah semua fitur berada dalam bentuk numerik, langkah selanjutnya adalah standarisasi data. Standarisasi dilakukan untuk menyamakan skala antar fitur agar tidak ada fitur yang mendominasi proses klasterisasi hanya karena memiliki rentang nilai yang lebih besar. Dalam penelitian ini digunakan metode *RobustScaler*, yang memiliki keunggulan dalam mengurangi pengaruh *outlier* dibandingkan metode standarisasi lain seperti *Min-Max Scaling* atau *StandardScaler*.

*RobustScaler* melakukan transformasi data berdasarkan nilai median dan *interquartile range* (IQR), bukan berdasarkan nilai rata-rata dan standar deviasi. Hal ini menjadikan proses standarisasi lebih tahan terhadap data ekstrim atau penyimpangan nilai yang signifikan. Seluruh fitur numerik yang telah dipilih sebagai input klasterisasi kemudian diskalakan menggunakan metode ini dan disimpan dalam bentuk *array* yang telah dinormalisasi.

Dengan *preprocessing* yang meliputi konversi format data dan standarisasi skala nilai, dataset yang dihasilkan telah siap untuk dianalisis menggunakan algoritma *X-Means* dalam tahap selanjutnya.

### 3.3.3 Explorasi Data Analisis

Tahapan *Exploratory Data Analysis (EDA)* dilakukan untuk memahami karakteristik dan struktur data sebelum dilakukan proses klasterisasi. EDA membantu dalam mengevaluasi distribusi, deteksi nilai ekstrem (*outlier*), serta mengidentifikasi hubungan antar fitur. Dalam penelitian ini, EDA mencakup lima komponen utama, yaitu analisis statistik deskriptif, analisis distribusi, identifikasi *outlier*, analisis korelasi, dan perhitungan multikolinearitas melalui nilai VIF (*Variance Inflation Factor*).

a. Analisis Distribusi

Distribusi data dianalisis dengan menggunakan visualisasi histogram dan *kernel density estimation (KDE)*. Setiap fitur divisualisasikan dalam bentuk histogram untuk melihat bentuk sebaran data, apakah simetris, miring ke kanan atau kiri, serta mengidentifikasi kemungkinan nilai-nilai ekstrim secara visual. Selain itu, fitur *Status Pembayaran* divisualisasikan menggunakan *countplot* untuk melihat frekuensi jumlah pelanggan yang telah melunasi pembayaran dibandingkan dengan yang belum.

b. Identifikasi *Outlier*

Deteksi *outlier* dilakukan menggunakan *boxplot* untuk masing-masing fitur numerik. Visualisasi ini memudahkan identifikasi nilai-nilai yang berada jauh dari rentang interkuartil (*IQR*) dan ditandai dengan titik-titik di luar *whisker*. Keberadaan *outlier* penting untuk diperhatikan karena dapat mempengaruhi hasil klusterisasi. Beberapa fitur seperti *Jumlah Transaksi* dan *Selisih* diketahui memiliki nilai ekstrem yang signifikan.

c. Analisis Korelasi

Selanjutnya dilakukan analisis korelasi antar fitur numerik menggunakan metode *Pearson*. Hasil analisis disajikan dalam bentuk heatmap untuk mempermudah identifikasi kekuatan dan arah hubungan linier antar fitur. Korelasi yang tinggi antara dua fitur dapat mengindikasikan redundansi informasi, sehingga perlu menjadi perhatian saat proses seleksi fitur untuk klusterisasi.

d. Perhitungan *Variance Inflation Factor (VIF)*

Untuk mendukung identifikasi multikolinearitas, dilakukan perhitungan nilai *Variance Inflation Factor (VIF)* pada seluruh fitur numerik. VIF digunakan untuk mengukur sejauh mana sebuah fitur dapat dijelaskan oleh fitur lainnya dalam dataset.

Fitur dengan nilai VIF tinggi (umumnya lebih dari 10) menunjukkan adanya multikolinearitas tinggi yang dapat mengganggu hasil klasterisasi, dan karena itu perlu dipertimbangkan untuk dieliminasi atau diganti.

Dari hasil analisis korelasi dan VIF, dipilih lima fitur utama yang akan digunakan dalam proses klasterisasi, yaitu Jumlah Transaksi, Harga, Jumlah Terlambat, Selisih, dan Status Pembayaran. Fitur-fitur tersebut kemudian dikonversi ke dalam bentuk *array* numerik (*NumPy array*) sebagai input untuk proses implementasi algoritma *X-Means* pada tahap selanjutnya.

#### 3.3.4 Implementasi *X-Means*

Setelah data di standarisasi dan transformasi menggunakan metode *RobustScaler*, langkah selanjutnya dalam penelitian ini adalah menerapkan algoritma *X-Means* untuk melakukan proses segmentasi pelanggan berdasarkan perilaku pembayaran mereka. Algoritma *X-Means* dipilih karena memiliki keunggulan dalam menentukan jumlah klaster dengan komputasi yang lebih cepat dibandingkan algoritma *K-Means* yang memerlukan nilai  $k$  (jumlah klaster) ditentukan terlebih dahulu sebelum proses komputasi.

Secara umum, *X-Means* merupakan perluasan dari algoritma *K-Means* yang mengintegrasikan proses evaluasi internal menggunakan metrik *Bayesian Information Criterion (BIC)* untuk menguji apakah suatu klaster perlu dibagi lebih lanjut atau tidak. Proses ini diawali dengan pembentukan sejumlah kecil klaster awal (biasanya dua), kemudian algoritma melakukan proses *splitting* pada masing-masing klaster secara rekursif, dengan mengevaluasi apakah pemisahan tersebut memberikan peningkatan skor BIC. Jika pemisahan memberikan nilai BIC yang lebih tinggi, maka klaster akan dipecah menjadi dua; jika tidak, maka struktur klaster dipertahankan. Dengan pendekatan ini, *X-Means* mampu beradaptasi terhadap struktur distribusi data dan membentuk jumlah klaster yang optimal tanpa intervensi manual.

Pada implementasinya, data numerik hasil transformasi digunakan sebagai masukan (input) ke dalam fungsi *X-Means*. Proses klasterisasi ini dilakukan dengan bantuan pustaka *scikit-learn* yang dimodifikasi dengan pustaka tambahan untuk mendukung ekstensi algoritma *X-Means*, karena *X-Means* tidak tersedia secara default di dalam modul dasar *scikit-learn*. Model dijalankan dengan parameter seperti batas maksimum jumlah klaster, metode inisialisasi *centroid*, dan jumlah iterasi maksimum. Selama iterasi, setiap calon klaster dinilai menggunakan fungsi penalti berbasis kompleksitas model, sehingga hasil akhir tidak hanya mempertimbangkan kedekatan titik data terhadap pusat klaster, tetapi juga kestabilan dan efisiensi segmentasi secara keseluruhan.

Hasil dari proses *X-Means* ini berupa label klaster yang dialokasikan untuk setiap observasi pelanggan, yang mencerminkan pola pembayaran yang serupa dalam satu kelompok. Klaster-klaster yang terbentuk kemudian dianalisis dan divisualisasikan untuk memahami perbedaan karakteristik antar kelompok pelanggan. Selanjutnya, evaluasi terhadap kualitas segmentasi dilakukan menggunakan metrik internal seperti *Silhouette Score*, yang digunakan untuk mengukur konsistensi internal dan pemisahan antar klaster.

Dengan demikian, penerapan *X-Means* pada penelitian ini memungkinkan terbentuknya segmentasi pelanggan yang lebih alami dan objektif berdasarkan pola pembayaran aktual, tanpa bias dari asumsi jumlah klaster awal. Pendekatan ini tidak hanya meningkatkan akurasi model segmentasi, tetapi juga menyediakan dasar yang kuat untuk pengambilan keputusan dalam strategi manajemen pelanggan yang lebih responsif dan berbasis data.

### 3.3.5 Evaluasi Model

Evaluasi model klasterisasi merupakan tahap penting dalam proses segmentasi data untuk memastikan bahwa klaster yang terbentuk benar-benar merepresentasikan struktur alami data dan memiliki kualitas yang baik. Karena klasterisasi merupakan pendekatan *unsupervised learning*

yang tidak memiliki label atau ground truth, maka evaluasi dilakukan menggunakan metrik internal. Penelitian ini menggunakan tiga metrik evaluasi, yaitu *Silhouette Score*, *Davies-Bouldin Index* (DBI), dan *Calinski-Harabasz Index* (CHI) untuk menilai performa dari hasil klasterisasi menggunakan algoritma *X-Means*.

*Silhouette Score* mengukur seberapa mirip suatu titik data dengan klaster tempatnya berada dibandingkan dengan klaster terdekat lainnya. Nilai ini dihitung untuk setiap observasi dan dirata-ratakan untuk seluruh dataset. Nilai *Silhouette* berkisar antara -1 hingga 1. Nilai mendekati 1 menunjukkan bahwa data sangat sesuai dengan klasternya dan sangat berbeda dengan klasterlain, sedangkan nilai mendekati 0 menunjukkan tumpang tindih antar klaster. Nilai negatif menunjukkan bahwa data lebih cocok berada di klaster lain.

*Davies-Bouldin Index* (DBI) adalah metrik yang digunakan untuk mengevaluasi seberapa baik pemisahan antar klaster dan kompaknya masing-masing klaster. Nilai DBI dihitung berdasarkan rasio jarak antara pusat klaster dan penyebaran dalam klaster (*intra-cluster distance*). Semakin rendah nilai DBI, semakin baik kualitas klaster karena menunjukkan bahwa klaster saling berjauhan dan tidak tumpang tindih.

*Calinski-Harabasz Index*, atau disebut juga *Variance Ratio Criterion*, mengevaluasi kualitas klaster berdasarkan rasio antara dispersi antar klaster (*between-cluster dispersion*) dan dispersi dalam klaster (*within-cluster dispersion*). Semakin tinggi nilai CHI, semakin baik pemisahan antar klaster dan semakin padat masing-masing klaster.

Dengan menggunakan ketiga metrik ini secara bersamaan, evaluasi klasterisasi dalam penelitian ini menjadi lebih komprehensif, mencakup aspek jarak antar klaster, kepadatan internal, serta kestabilan struktur klaster. Pendekatan evaluasi ini memberikan dasar yang kuat untuk menyimpulkan kualitas dan reliabilitas segmentasi pelanggan yang dihasilkan oleh algoritma *X-Means*.

### 3.3.6 Interpretasi Klaster

Tahap interpretasi klaster dilakukan untuk memahami karakteristik dari masing-masing kelompok hasil klasterisasi. Setelah proses segmentasi menggunakan algoritma *X-Means* berhasil mengelompokkan data ke dalam sejumlah klaster optimal, dilakukan analisis lanjutan terhadap setiap klaster guna mengetahui profil pelanggan berdasarkan pola pembayaran. Analisis ini dilakukan terhadap beberapa fitur penting yang berkaitan langsung dengan perilaku pembayaran, seperti status pembayaran dan jumlah keterlambatan.

Untuk setiap klaster yang terbentuk, dilakukan perhitungan proporsi *Status Pembayaran* yang terdiri dari dua kategori, yaitu “Lunas” (1) dan “Belum Lunas” (0). Nilai ini dinyatakan dalam bentuk persentase terhadap total anggota klaster, guna mengetahui dominasi perilaku pembayaran dalam setiap kelompok. Klaster dengan persentase lunas yang tinggi menunjukkan bahwa mayoritas pelanggan dalam kelompok tersebut menyelesaikan kewajiban pembayarannya, sementara klaster dengan proporsi belum lunas yang tinggi mengindikasikan adanya risiko yang besar.

Selain itu, dihitung rata-rata Jumlah Terlambat, yang merepresentasikan frekuensi keterlambatan pembayaran yang dilakukan oleh pelanggan dalam setiap klaster. Semakin tinggi nilai keterlambatan, semakin besar kecenderungan kelompok tersebut menjadi pelanggan yang berisiko. Fitur ini menjadi indikator penting dalam menentukan tingkat kepatuhan pelanggan terhadap jadwal angsuran. Melalui proses interpretasi ini, klaster tidak hanya menjadi sekumpulan angka, tetapi mewakili perilaku nyata pelanggan yang dapat ditindaklanjuti.

### 3.3.7 Visualisasi Klaster

Visualisasi klaster dilakukan untuk memberikan pemahaman intuitif terhadap hasil segmentasi pelanggan berdasarkan pola pembayaran mereka. Setelah proses klasterisasi selesai dilakukan menggunakan algoritma *X-Means*, visualisasi digunakan sebagai alat bantu untuk mengevaluasi

pemisahan antar klaster serta mengidentifikasi karakteristik dari setiap kelompok pelanggan secara visual.

Salah satu visualisasi yang digunakan adalah *countplot* untuk menampilkan jumlah pelanggan berdasarkan status pembayaran dalam masing-masing klaster. Visualisasi ini memperlihatkan proporsi pelanggan yang telah melunasi (label 1) dan yang belum melunasi pembayaran (label 0) dalam setiap klaster. Informasi bisa untuk mengamati distribusi risiko finansial di masing-masing kelompok, sekaligus menjadi dasar dalam perumusan strategi penanganan yang berbeda antar segmen.

Selanjutnya, dilakukan visualisasi menggunakan algoritma *t-distributed Stochastic Neighbor Embedding* (t-SNE) untuk memproyeksikan data. t-SNE dipilih karena mampu mempertahankan hubungan lokal antar data, sehingga representasi visual yang dihasilkan tetap mencerminkan struktur asli data. Hasil reduksi dimensi divisualisasikan dalam bentuk scatter plot, di mana tiap titik merepresentasikan satu pelanggan, dan warna menunjukkan klaster tempat pelanggan tersebut tergabung. Visualisasi ini membantu mengamati tingkat pemisahan antar klaster serta mendeteksi adanya potensi tumpang tindih antar kelompok.

Untuk memperjelas posisi pusat distribusi setiap klaster, ditambahkan simbol pusat klaster (*centroid*) ke dalam plot, yang dihitung berdasarkan nilai rata-rata komponen *t-SNE* dari masing-masing kelompok. Pusat klaster ditandai dengan simbol “X” berwarna merah, sehingga dapat menunjukkan seberapa tersebar data dalam satu klaster terhadap pusatnya.

Dengan visualisasi, hasil klasterisasi dapat diamati dengan lebih mudah, baik dari segi sebaran data, tingkat keterpisahan antar klaster, maupun kepadatan data dalam tiap kelompok. Visualisasi ini tidak hanya memperkuat temuan numerik dari proses evaluasi, tetapi juga memberikan pemahaman yang lebih baik bagi pengambil keputusan dalam memahami profil pelanggan secara mendalam berdasarkan pola pembayaran mereka.



### 3.3.8 Rekomendasi Strategi

Dalam penelitian ini, hasil segmentasi pelanggan tidak hanya digunakan untuk mengetahui pola pembayaran, tetapi juga sebagai dasar dalam merumuskan strategi bisnis yang sesuai dengan karakteristik tiap segmen. Secara teoritis, segmentasi pelanggan memungkinkan perusahaan untuk melakukan diferensiasi layanan, menyusun kebijakan pembayaran yang tepat, serta mengalokasikan sumber daya secara lebih efisien. Pendekatan ini sejalan dengan konsep manajemen risiko, di mana setiap kelompok pelanggan memiliki tingkat risiko yang berbeda sehingga memerlukan perlakuan dan strategi yang berbeda pula.

Dalam sistem *inhouse* syariah, strategi yang dibangun harus tetap berlandaskan prinsip syariah, yaitu tanpa riba, tanpa denda, dan berbasis musyawarah. Oleh karena itu, rekomendasi strategi yang dihasilkan dari analisis *Clustering* difokuskan pada tiga aspek utama, yaitu pencegahan risiko melalui *monitoring* dan edukasi, pengembangan hubungan jangka panjang melalui program loyalitas, serta pemulihan pembayaran melalui mekanisme restrukturisasi yang adil. Dengan demikian, proses analisis tidak hanya berhenti pada pemetaan klaster, tetapi juga menghasilkan kerangka teoritis bagi perusahaan dalam mengembangkan strategi bisnis berbasis syariah

## 3.3. Desain Sistem

Hasil dari penelitian ini adalah pembuatan antarmuka pengguna atau *user interface* yang bertujuan untuk mempermudah pengguna dalam mengakses, mengeksplorasi, dan menganalisis hasil segmentasi pelanggan berdasarkan data transaksi dan pembayaran properti. Aplikasi ini dikembangkan untuk menyajikan visualisasi hasil klasterisasi secara interaktif agar pengguna non-teknis dapat memahami karakteristik tiap klaster dengan lebih mudah.


Antarmuka sistem dibangun menggunakan *Streamlit*, yaitu *framework* berbasis bahasa pemrograman Python yang sangat populer untuk pengembangan aplikasi web interaktif, khususnya dalam bidang *data science* dan *machine learning*. Dalam implementasinya, bagian *backend* atau logika program dikembangkan

menggunakan Python karena bahasa ini memiliki beragam pustaka (*library*) yang mendukung proses analisis data, pemodelan, visualisasi, hingga *deployment*. Beberapa *library* yang digunakan dalam sistem ini antara lain *pandas* untuk manipulasi data, *scikit-learn* untuk model klasterisasi *X-Means*, serta *matplotlib*, *seaborn*, dan *plotly* untuk visualisasi grafik hasil segmentasi.

Selain menjalankan proses seperti membaca data, membersihkan data dari nilai ekstrem (*outlier*), menormalisasi data, hingga menjalankan algoritma *X-Means* dan mengevaluasi hasil klasterisasi menggunakan *Silhouette Score*, *Davies Bouldin Index*, dan *Calinski-Harabasz*, sistem ini juga menyajikan hasil interpretasi setiap klaster dalam bentuk grafik dan tabel. Bagian tampilan atau *frontend* dari aplikasi dibuat lebih atraktif dengan bantuan CSS (*Cascading Style Sheets*) yang diintegrasikan ke dalam komponen *Streamlit* melalui kode HTML dan *markdown* di Python. Hal ini bertujuan agar aplikasi terlihat rapi, mudah digunakan, dan nyaman saat diakses pengguna.

Dalam proses pengembangan, seluruh *source code* disimpan dan dikendalikan melalui GitHub, yang berfungsi sebagai repositori *online* dan kolaborasi proyek. GitHub memungkinkan pencatatan riwayat pengembangan kode secara rapi serta mempermudah publikasi aplikasi. Untuk *deployment*, aplikasi ini dapat dijalankan secara *online* melalui *Streamlit Cloud* dengan hanya menghubungkan repositori GitHub ke *platform* tersebut. Dengan demikian, aplikasi dapat langsung diakses oleh pengguna melalui *browser* tanpa perlu instalasi lokal.

Sistem ini diharapkan dapat menjadi alat bantu analisis pelanggan berbasis data yang praktis, ringan, dan interaktif, serta dapat mendukung pengambilan keputusan strategis di perusahaan berdasarkan profil pembayaran pelanggan yang terbentuk dari hasil klasterisasi. Pada gambar berikut adalah diagram alir pada desain sistemnya.



**Gambar 3.2.** Diagram alir Desain Sistem

Gambar 3.2 menjelaskan alur sistem aplikasi analisis klasterisasi pelanggan berbasis web yang dirancang menggunakan pendekatan *machine learning* dan visualisasi interaktif. Alur dimulai dari antarmuka pengguna dengan fitur "Tentang Aplikasi", dilanjutkan dengan proses unggah data yang terbagi menjadi dua jenis, yaitu data angsuran (berisi catatan pembayaran pelanggan) dan data utama (berisi informasi harga dan properti). Kedua data ini kemudian melewati tahap preprocessing yang mencakup pembersihan data, peringkasan transaksi per unit pelanggan, penggabungan informasi harga, serta perhitungan tingkat keterlambatan pembayaran. Hasil dari proses ini adalah dataset yang siap untuk dianalisis.

Tahap selanjutnya adalah pemilihan fitur yang relevan untuk proses klasterisasi. Fitur-fitur ini ditentukan berdasarkan eksplorasi data sebelumnya, termasuk distribusi nilai dan korelasi antar fitur. Setelah fitur dipilih, sistem melakukan pemodelan klaster menggunakan algoritma *X-Means*, menentukan jumlah klaster optimal sesuai dengan pola distribusi data dan ketentuan *threshold*. Hasil dari proses klasterisasi kemudian dievaluasi menggunakan tiga metrik internal yaitu *Silhouette Score*, *Davies Bouldin Index*, dan *Calinski-Harabasz*.

*Score*. Ketiga metrik ini digunakan untuk menilai kualitas dan validitas pembentukan klaster secara objektif tanpa memerlukan label data.

Selanjutnya, sistem menyediakan visualisasi hasil klasterisasi untuk menampilkan penyebaran data pelanggan. Setelah divisualisasikan, pengguna dapat melihat hasil interpretasi masing-masing klaster yang menjelaskan karakteristik perilaku pembayaran berdasarkan fitur yang dianalisis. Sistem juga menyediakan fitur *download* data, memungkinkan pengguna mengunduh hasil klaster beserta visualisasi dan statistik pendukung untuk keperluan lanjutan. Tahapan ini menutup keseluruhan proses sistem, dengan harapan hasil segmentasi dapat digunakan untuk menyusun strategi komunikasi dan penanganan pelanggan secara lebih tepat sasaran.

## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1. Persiapan Data

##### 4.1.1. Membaca Data

Tahap awal dalam proses analisis data adalah membaca dan memuat dataset yang akan digunakan. Menggunakan dua file data, file pertama berisi catatan pembayaran angsuran dari masing-masing pelanggan. File kedua berisi informasi harga properti. Proses pembacaan data dilakukan menggunakan *library pandas* dalam bahasa pemrograman *Python*, seperti pada kode program 4.1.

| Kode Program 4.1 Membaca Data |
|-------------------------------|
|-------------------------------|

|                                                                                                                                                                                                                         |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre># Membaca data dari Excel df1 = pd.read_excel('angsuran.xlsx') df1  # Membaca data dari Excel df2 = pd.read_excel('data utama.xlsx') df2  # Membaca data dari Excel df3 = pd.read_excel('angsuran.xlsx') df3</pre> |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

Setiap file yang dimuat kemudian ditampilkan dalam bentuk tabel untuk memverifikasi struktur data awal. Tabel 4.1 adalah data angsuran diberi nama 'df1' dan menggunakan file yang sama juga untuk 'df3'.

**Tabel 4.1.** Data Angsuran

| <i>Project</i>  | <b>Nomor Unit</b> | <b>Nominal</b> | <b>Transfer Bank /Cash</b> | <b>Tanggal Diterima</b> | <b>Tanggal Pembayaran</b> | <i>Unnamed: 6</i> |
|-----------------|-------------------|----------------|----------------------------|-------------------------|---------------------------|-------------------|
| Sawohan Tahap 1 | 1                 | 165000000.0    | Cash                       | 2019-03-26              | 2019-03-26 00:00:00       | 32019.0           |
| Sawohan Tahap 1 | 2                 | 165000000.0    | Cash                       | 2019-03-26              | 2019-03-26 00:00:00       | 32019.0           |
| ...             | ...               | ...            | ...                        | ...                     | ...                       | ...               |
| Sawohan Tahap 1 | RK3               | 2500000.0      | BSI                        | 2024-10-10              | 2024-10-01 00:00:00       | 102024.0          |

Tabel 4.2 adalah dataset kedua yaitu data utama diberi nama 'df2'. Data ini digunakan untuk mendapatkan informasi harga tiap unit yang dibeli.

**Tabel 4.2.** Data Utama

| <b>No. Unit Awal</b> | <b>Nama</b> | <b>Cluster</b>  | <b>Harga</b> | <b>Jumlah DP</b> | <b>...</b> |
|----------------------|-------------|-----------------|--------------|------------------|------------|
| 1                    | A1          | Ruko Gate Depan | 165000000    | 165000000        | ...        |
| 2                    | A2          | Ruko Gate Depan | 165000000    | 165000000        | ...        |
| ...                  | ...         | ...             | ...          | ...              | ...        |
| RK3                  | A528        | Sawarna         | 200.000.000  | 50.000.000       | ...        |

#### 4.1.2. Seleksi Fitur

Seleksi fitur dilakukan untuk memilih fitur yang akan digunakan dalam proses penelitian. Tahapan ini bertujuan untuk menyederhanakan data, menghindari informasi yang tidak dibutuhkan, dan memfokuskan penelitian pada fitur-fitur yang berkaitan langsung dengan tujuan penelitian. Berikut adalah script untuk seleksi fitur sesuai dengan kode program 4.2.

**Kode Program 4.2 Seleksi Fitur**

```
# Persiapkan Data
df1 = df1[['Nomor Unit', 'Nominal']]
df1

# Persiapkan Data
df2 = df2[['F', 'Unnamed: 3']]
df2

# Persiapan Data
df3 = df3[['Nomor Unit', 'Tanggal Diterima', 'Tanggal
Pembayaran']]
df3
```

Pada tahap ini, dilakukan pemilihan fitur dari tiga *DataFrame*. Pertama, df1, dipilih dua fitur yaitu, 'Nomor Unit' dan 'Nominal' seperti pada Tabel 4.3.

**Tabel 4.3.** Pemilihan Data Angsuran pertama

| Nomor Unit | Nominal     |
|------------|-------------|
| 1          | 165000000.0 |
| 2          | 165000000.0 |
| ...        | ...         |
| RK3        | 2500000.0   |

Fitur 'Nomor Unit' digunakan sebagai identifikasi unik masing-masing properti atau pelanggan, sedangkan 'Nominal' berisi informasi nilai pembayaran yang telah diterima dari pelanggan. Selanjutnya, dari 'df2', dipilih dua fitur yaitu, 'F' dan 'Unnamed: 3' seperti pada Tabel 4.4.

**Tabel 4.4.** Pemilihan Data Utama

| F   | Unnamed: 3 |
|-----|------------|
| 1   | 165000000  |
| 2   | 165000000  |
| ... | ...        |
| RK3 | 200000000  |

Meskipun nama fitur belum diberi label yang bermakna, namun berdasarkan struktur data, kolom-kolom ini menyimpan informasi mengenai harga properti dan kode unit. Terakhir, dari 'df3', dipilih fitur 'Nomor Unit', 'Tanggal Diterima', dan 'Tanggal Pembayaran' seperti pada tabel 4.5.

**Tabel 4.5.** Pemilihan Data Angsuran Kedua

| Nomor Unit | Tanggal Diterima | Tanggal Pembayaran  |
|------------|------------------|---------------------|
| 1          | 2019-03-26       | 2019-03-26 00:00:00 |
| 2          | 2019-03-26       | 2019-03-26 00:00:00 |
| ...        | ...              | ...                 |
| RK3        | 2024-10-10       | 2024-10-01 00:00:00 |

Fitur tersebut digunakan dalam menganalisis waktu pembayaran, khususnya untuk menghitung jumlah keterlambatan pembayaran setiap pelanggan. Informasi ini dibutuhkan untuk membentuk fitur baru 'Jumlah Keterlambatan'. Dengan melakukan seleksi fitur ini, maka data yang digunakan pada tahap-tahap berikutnya akan lebih focus dan sesuai dengan tujuan penelitian.

#### 4.1.3. *Missing Value*

Dilakukan pemeriksaan *missing value* pada setiap dataset yang telah melalui proses seleksi fitur. *Missing value* atau nilai kosong (NaN) dapat mengganggu proses analisis dan menyebabkan bias atau kesalahan dalam hasil klasterisasi jika tidak ditangani dengan tepat. Berikut adalah kode program 4.3 untuk memeriksa *missing value*.

**Kode Program 4.3** Pengecekan *Missing Value*

```
df1.isna().sum()
df2.isna().sum()
df3.isna().sum()
```

Pemeriksaan *missing value* menggunakan perintah 'df.isna().sum()' menunjukkan bahwa terdapat *missing value* pada ketiga dataset sesuai dengan tabel 4.6 memperlihatkan *missing value* pada masing-masing data.



**Tabel 4.6.** Output Missing Value

|           |                       |
|-----------|-----------------------|
| Dataset 1 | Nomor Unit: 4         |
|           | Nominal: 5            |
| Dataset 2 | F: 1                  |
|           | Unnamed 3: 159        |
| Dataset 3 | Nomor Unit: 4         |
|           | Tanggal Diterima: 5   |
|           | Tanggal Pembayaran: 3 |

Pembersihan data dengan perintah ‘dropna’ seperti pada kode program 4.4 dilakukan untuk mengatasi *missing value* pada ketiga dataset. Setelah proses dilakukan, diperiksa kembali jumlah *missing value* dan hasilnya menunjukkan bahwa seluruh nilai kosong telah berhasil dihapus.

**Kode Program 4.4** Mengatasi Missing Value

```
df1 = df1.dropna()
df1.isna().sum()

df2 = df2.dropna()
df2.isna().sum()

df3 = df3.dropna()
df3.isna().sum()
```

Baris-baris yang mengandung nilai kosong, dihapus karena tidak memberikan pengaruh signifikan terhadap keseluruhan dataset. Setelah teratasi seluruh *missing value*, dataset dari tahap ini telah dalam kondisi siap untuk diproses tahapan selanjutnya.

#### 4.1.4. Konversi Tipe Data

Setiap fitur dilakukan pemeriksaan tipe data menggunakan perintah ‘df.info()’. Dari hasil pengecekan, sebagian besar fitur telah memiliki tipe data yang sesuai. Namun, ada dua fitur pada ‘df3’ yang tipe datanya belum sesuai. Fitur Tanggal Diterima dan Tanggal Pembayaran, masih dalam tipe data objek dan belum dikenali sebagai tipe data tanggal. Dilakukan konversi tipe data pada ‘df3’ sesuai dengan kode program 4.5.

**Kode Program 4.5 Konversi Tipe Data**

```
# Mengkonversi kolom tanggal menjadi format datetime
df3['Tanggal Diterima'] = pd.to_datetime(df3['Tanggal
Diterima'], errors='coerce', dayfirst=True)
df3['Tanggal Pembayaran'] =
pd.to_datetime(df3['Tanggal Pembayaran'],
errors='coerce', dayfirst=True)
```

Proses ini menggunakan perintah ‘pd.to\_datetime()’ dari pustaka pandas. Parameter ‘errors=‘coerce’ digunakan untuk menghindari kegagalan konversi, sehingga jika terdapat nilai yang tidak sesuai tipe data, maka akan secara otomatis dikonversi menjadi *NaT* (*Not a Time*). Selain itu, parameter ‘dayfirst=True’ digunakan agar tipe data tanggal dibaca dalam urutan hari-bulan-tahun (dd-mm-yyyy) sesuai dengan penulisan di Indonesia.

#### 4.1.5. Agregasi dan Penggabungan Data

Tahapan ini dimulai dengan melakukan agregasi data untuk data ‘df1’ berdasarkan fitur ‘*Nomor Unit*’ untuk merangkum seluruh transaksi yang dilakukan setiap pelanggan. Proses agregasi dilakukan sesuai dengan kode program 4.6.

**Kode Program 4.6 Agregasi Data**

```
# Agregasi data berdasarkan 'Nomor Unit'
agg_df = df1.groupby('Nomor Unit').agg({
    'Nominal': ['count', 'sum'],
}).reset_index()

agg_df.columns = ['Nomor Unit', 'Jumlah Transaksi',
'Total Pembayaran']
agg_df
```

Agregasi dilakukan dengan menghitung dua informasi utama dari fitur ‘*Nominal*’, yaitu jumlah transaksi dan total pembayaran yang telah dilakukan. Hasil agregasi ini disimpan dalam bentuk *DataFrame* baru dengan nama fitur ‘*Nomor Unit*’, ‘*Jumlah Transaksi*’, dan ‘*Total Pembayaran*’.

**Tabel 4.7.** Agregasi df1

| Nomor Unit | Jumlah Transaksi | Total Pembayaran |
|------------|------------------|------------------|
| 1          | 1                | 165000000.0      |
| 2          | 1                | 165000000.0      |
| ...        | ...              | ...              |
| RK3        | 61               | 200000000.0      |

Selanjutnya, dilakukan penyesuaian nama kolom pada data harga properti. Pada data awal, kolom *'Nomor Unit'* dan *'Harga'* masih menggunakan nama tidak standar seperti *'F'* dan *'Unnamed: 3'*, sehingga perlu dilakukan penggantian nama fitur menggunakan fungsi *rename()* sesuai dengan kode program 4.7. Penggantian ini penting agar proses penggabungan data berikutnya dapat dilakukan dengan benar, karena penggabungan membutuhkan kesamaan nama fitur sebagai acuan penggabungan (*key*).

**Kode Program 4.7** Mengganti nama fitur

```
# Mengganti nama fitur
df2 = df2.rename(columns={'F': 'Nomor Unit'})
df2 = df2.rename(columns={'Unnamed: 3': 'Harga'})
df2
```

Setelah nama fitur diselaraskan, langkah berikutnya adalah menggabungkan dataset hasil agregasi dengan data *'df2'* sesuai dengan kode program 4.8.

**Kode Program 4.8** Penggabungan df1 dan df2

```
if len(agg_df) == len(df2):
    dataset = pd.merge(agg_df, df2, on='Nomor Unit',
                      how='inner')
    print(dataset.head())
else:
    print("Gagal menggabungkan: jumlah baris tidak sama. Gunakan penggabungan berdasarkan kolom kunci seperti 'Nomor Unit'.")
```

Proses penggabungan dilakukan dengan menggunakan fungsi *merge()* dari *pandas*, yang menggabungkan data berdasarkan kolom '*Nomor Unit*'. Tabel 4.8 adalah hasil penggabungan data setelah di agregasi dan *df2*.

**Tabel 4.8.** Hasil Gabungan *df1* dan *df2*

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga     |
|------------|------------------|------------------|-----------|
| 1          | 1                | 165000000.0      | 165000000 |
| 2          | 1                | 165000000.0      | 165000000 |
| ...        | ...              | ...              | ...       |
| RK3        | 61               | 200000000.0      | 200000000 |

Setelah penggabungan data selesai, dilakukan perhitungan selisih antara fitur 'Total Pembayaran' dan 'Harga', membentuk fitur baru yaitu selisih. Proses perhitungan selisih sesuai dengan kode program 4.9.

| Kode Program 4.9 Menghitung selisih pembayaran                                                                                                    |
|---------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre># Menghitung selisih antara Pelunasan dan Total Pembayaran dataset['Selisih'] = dataset['Harga'] - dataset['Total Pembayaran'] dataset</pre> |

Tabel 4.9 adalah dataset hasil setelah dilakukan perhitungan dan penambahan fitur 'selisih'.

**Tabel 4.9.** Hasil Perhitungan Selisih Pembayaran

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga     | Selisih |
|------------|------------------|------------------|-----------|---------|
| 1          | 1                | 165000000.0      | 165000000 | 0.0     |
| 2          | 1                | 165000000.0      | 165000000 | 0.0     |
| ...        | ...              | ...              | ...       | ...     |
| RK3        | 61               | 200000000.0      | 200000000 | 0.0     |

Kode program 4.10 adalah script untuk memberikan tanda pelunasan unit. Jika selisih kurang dari 0 maka unit yang dibeli telah dilunasi, sebaliknya jika lebih dari 0 maka unit yang telah dibeli belum dilunasi.

| Kode Program 4.10 Menambahkan Status Pembayaran                                                                                                                                                                                                                                      |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre># Menambahkan status pembayaran berdasarkan selisih # Jika selisih ≤ 0 (nol atau minus) berarti Lunas, # jika selisih &gt; 0 berarti Belum Lunas dataset['Status Pembayaran'] = dataset['Selisih'].apply(     lambda x: "Lunas" if x &lt;= 0 else "Belum Lunas" ) dataset</pre> |

Tabel 4.10 adalah dataset hasil dari pemberian status pembayaran pada setiap unit.

**Tabel 4.10.** Penambahan Status Pembayaran

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga     | Selisih | Status Pembayaran |
|------------|------------------|------------------|-----------|---------|-------------------|
| 1          | 1                | 165000000.0      | 165000000 | 0.0     | Lunas             |
| 2          | 1                | 165000000.0      | 165000000 | 0.0     | Lunas             |
| ...        | ...              | ...              | ...       | ...     | ...               |
| RK3        | 61               | 200000000.0      | 200000000 | 0.0     | Lunas             |

Kode program 4.11 adalah menghitung berapa kali setiap unit melakukan keterlambatan pembayaran. Perhitungan keterlambatan menggunakan data 'df3'.

| Kode Program 4.11 Keterlambatan Pembayaran                                                                                                                                                                                                                  |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <pre># Filter untuk mendapatkan data yang terlambat bayar (Selisih Hari &gt; 0) df4 = df3[df3['Selisih Hari'] &gt; 0]  # Hitung jumlah keterlambatan per 'Nomor Unit' df5 = df4.groupby('Nomor Unit').size().reset_index(name='Jumlah Terlambat') df5</pre> |

Tabel 4.11 adalah data ‘df3’ yang telah dilakukan perhitungan selisih hari setiap unit membayar tepat waktu atau tidak.

**Tabel 4.11.** Perhitungan Keterlambatan Pembayaran

| Nomor Unit | Tanggal Diterima | Tanggal Pembayaran | Selisih Hari |
|------------|------------------|--------------------|--------------|
| 4          | 2021-05-27       | 2021-05-01         | 26           |
| 4          | 2022-02-25       | 2022-02-01         | 24           |
| ...        | ...              | ...                | ...          |
| RK3        | 2024-10-10       | 2024-10-01         | 9            |

Setelah diketahui selisih hari setiap unit yang terlambat membayar saat tanggal jatuh tempo, fitur selisih hari dijumlah untuk mengetahui jumlah keterlambatan yang dilakukan oleh setiap unit. Tabel 4.12 adalah jumlah keterlambatan yang dilakukan setiap unit.

**Tabel 4.12.** Jumlah Terlambat Setiap Unit

| Nomor Unit | Jumlah Terlambat |
|------------|------------------|
| 4          | 5                |
| 6          | 7                |
| ...        | ...              |
| RK3        | 39               |

Dataset yang telah digabungkan sebelumnya digabungkan kembali dengan data ‘df3’. Kemudian digunakan dalam proses penelitian selanjutnya. Penggabungan data dilakukan berdasarkan nomor unit dengan menggunakan ‘*merge()*’, tools yang telah disediakan oleh pandas sesuai dengan kode program 4.12.

**Kode Program 4.12** Penggabungan Data

```
Gabungkan dataset dengan data_terlambat berdasarkan
'Nomor Unit'
dataset = pd.merge(dataset, data_terlambat, on='Nomor
Unit', how='left')
dataset
```

Hasil penggabungan ini menghasilkan sebuah dataset komprehensif yang mencakup informasi penting seperti jumlah transaksi, total pembayaran, harga properti, dan jumlah keterlambatan untuk masing-masing pelanggan.

**Tabel 4.13.** Dataset Analisis

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga     | Selisih | Status Pembayaran | Jumlah Terlambat |
|------------|------------------|------------------|-----------|---------|-------------------|------------------|
| 1          | 1                | 165000000.0      | 165000000 | 0.0     | Lunas             | NaN              |
| 2          | 1                | 165000000.0      | 165000000 | 0.0     | Lunas             | NaN              |
| ...        | ...              | ...              | ...       | ...     | ...               | ...              |
| RK3        | 61               | 200000000.0      | 200000000 | 0.0     | Lunas             | 39.0             |

#### 4.1.6. *Missing Value*

Pada tahap akhir dari proses pembersihan data, dilakukan pengecekan ulang terhadap seluruh fitur yang terdapat dalam dataset gabungan menggunakan fungsi `dataset.isna().sum()` yang tertera pada kode program 4.13. Tujuan dari langkah ini adalah untuk memastikan bahwa seluruh nilai kosong (*missing value*) telah berhasil diidentifikasi dan ditangani sebelum proses analisis lebih lanjut dilakukan.

##### **Kode Program 4.13** Melihat Missing Value

```
dataset.isna().sum()
```

Berdasarkan hasil keluaran (*output*) yang ditampilkan dalam Tabel 4.14, dapat dilihat bahwa semua fitur seperti *Nomor Unit*, *Jumlah Transaksi*, *Total Pembayaran*, *Harga*, *Selisih*, dan *Status Pembayaran* telah bersih dari nilai kosong. Namun, pada kolom *Jumlah Terlambat* masih ditemukan sebanyak 100 data yang memiliki nilai kosong.

**Tabel 4.14.** Melihat Missing Value

| Fitur             | Missing Value |
|-------------------|---------------|
| Nomor Unit        | 0             |
| Jumlah Transaksi  | 0             |
| Total Pembayaran  | 0             |
| Harga             | 0             |
| Selisih           | 0             |
| Status Pembayaran | 0             |
| Jumlah Terlambat  | 100           |

Kolom *Jumlah Terlambat* merupakan hasil perhitungan yang bergantung pada keberadaan data tanggal pembayaran dan tanggal diterima. Oleh karena itu, kemungkinan nilai kosong muncul karena tidak adanya catatan keterlambatan pada beberapa pelanggan. Untuk mengatasi hal ini, dilakukan pengisian nilai kosong dengan nilai 0 menggunakan fungsi `fillna(0)` sesuai dengan kode program 4.14, yang mengindikasikan bahwa pelanggan terkait tidak memiliki keterlambatan pembayaran. Selain itu, agar format data tetap seragam dan dapat digunakan dalam perhitungan numerik berikutnya, tipe data fitur tersebut juga diubah ke bentuk *integer* menggunakan `astype(int)`.

| <b>Kode Program 4.14</b> Mengatasi Missing Value                                                                            |
|-----------------------------------------------------------------------------------------------------------------------------|
| <pre># Isi nilai NaN dengan 0 dataset['Jumlah Terlambat'] = dataset['Jumlah Terlambat'].fillna(0).astype(int) dataset</pre> |

Setelah proses pengisian dilakukan, dataset kembali diperiksa, dan hasilnya menunjukkan bahwa seluruh nilai kosong pada kolom *Jumlah Terlambat* telah berhasil diatasi. Tabel 4.15 adalah tabel setelah *missing value* berhasil diatasi.



Tabel 4.15. Dataset Penelitian

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga         | Selisih | Status Pembayaran | Jumlah Terlambat |
|------------|------------------|------------------|---------------|---------|-------------------|------------------|
| 1          | 1                | 16500000<br>0.0  | 165000<br>000 | 0.0     | Lunas             | 0                |
| 2          | 1                | 16500000<br>0.0  | 165000<br>000 | 0.0     | Lunas             | 0                |
| ...        | ...              | ...              | ...           | ...     | ...               | ...              |
| RK3        | 61               | 20000000<br>0.0  | 200000<br>000 | 0.0     | Lunas             | 39               |

Dengan demikian, seluruh dataset kini telah bersih dari *missing value*, dan siap digunakan untuk proses *preprocessing* lanjutan seperti standarisasi data dan pemodelan klasterisasi.

## 4.2. Data Preprocessing

### 4.2.1. Transformasi Data

Setelah seluruh data dari beberapa sumber berhasil digabungkan dan nilai kosong telah ditangani, langkah selanjutnya dalam proses transformasi data adalah memastikan bahwa setiap fitur berada dalam tipe data yang sesuai. Hal ini penting dilakukan untuk mendukung keakuratan pemrosesan data, terutama saat fitur tersebut digunakan dalam proses analisis dan pemodelan klasterisasi. Beberapa kolom pada dataset masih memiliki tipe data yang belum konsisten, seperti *object* atau *float64*, padahal dalam analisis numerik dibutuhkan tipe *int* atau *string* sesuai konteks masing-masing. Mengganti tipe data bisa dilakukan sesuai dengan kode program 4.15.

#### Kode Program 4.15 Mengganti Tipe Data

```
# Mengganti tipe data
dataset['Nomor Unit'] = dataset['Nomor Unit'].astype('string')
dataset['Total Pembayaran'] = dataset['Total Pembayaran'].astype(int)
dataset['Harga'] = dataset['Harga'].astype(int)
```

**Kode Program 4.15** Mengganti Tipe Data

```
dataset['Selisih'] = dataset['Selisih'].astype(int)
dataset['Status Pembayaran'] = dataset['Status
Pembayaran'].astype('string')
dataset.info()
```

Dalam penelitian ini, kolom Status Pembayaran awalnya memiliki nilai kategorik berupa teks, yaitu "*Lunas*" dan "*Belum Lunas*". Namun, untuk mendukung proses analisis numerik dan klasterisasi, nilai-nilai tersebut perlu diubah menjadi bentuk numerik. Oleh karena itu, dilakukan transformasi menggunakan teknik *binary encoding* seperti pada kode program 4.16, di mana label "*Lunas*" dikonversi menjadi nilai 1, dan label "*Belum Lunas*" dikonversi menjadi 0. Transformasi ini diterapkan melalui skrip berikut:

**Kode Program 4.16** Encoding Status Pembayaran

```
# Mengubah status pembayaran menjadi numerik (1 untuk
Lunas, 0 untuk Belum Lunas)
dataset['Status Pembayaran'] = dataset['Status
Pembayaran'].apply(lambda x: 1 if x == 'Lunas' else 0)
dataset
```

Proses ini bertujuan untuk memastikan bahwa algoritma klasterisasi seperti *X-Means* dapat memproses informasi status pembayaran secara numerik tanpa mengasumsikan hubungan ordinal antara dua kategori tersebut. Data pada kolom Status Pembayaran berubah menjadi seperti Tabel 4.16.

**Tabel 4.16.** Data Hasil Encoding

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga     | Selisih | Status Pembayaran | Jumlah Terlambat |
|------------|------------------|------------------|-----------|---------|-------------------|------------------|
| 1          | 1                | 165000000        | 165000000 | 0       | 1                 | 0                |
| 2          | 1                | 165000000        | 165000000 | 0       | 1                 | 0                |
| ...        | ...              | ...              | ...       | ...     | ...               | ...              |

| Nomor Unit | Jumlah Transaksi | Total Pembayaran | Harga     | Selisih | Status Pembayaran | Jumlah Terlambat |
|------------|------------------|------------------|-----------|---------|-------------------|------------------|
| RK3        | 61               | 200000000        | 200000000 | 0       | 1                 | 39               |

#### 4.2.2. Standarisasi Data

Sebelum proses standarisasi dilakukan, langkah awal adalah menentukan fitur-fitur mana saja yang akan digunakan dalam proses klusterisasi. Pemilihan fitur ini bertujuan untuk memastikan bahwa hanya fitur yang relevan dan representatif terhadap perilaku pelanggan yang disertakan dalam proses pembentukan klaster. Dalam penelitian ini, fitur-fitur yang dipilih tertera pada tabel 4.17.

**Tabel 4.17.** Penjelasan Fitur

| Fitur             | Deskripsi                                                             |
|-------------------|-----------------------------------------------------------------------|
| Jumlah Transaksi  | Menunjukkan seberapa sering pelanggan melakukan pembayaran            |
| Total Pembayaran  | Total nominal yang telah dibayarkan oleh pelanggan                    |
| Harga             | Harga properti yang dimiliki                                          |
| Selisih           | Selisih antara total pembayaran dan harga sebagai indikator pelunasan |
| Status Pembayaran | Status akhir apakah pelanggan sudah lunas (1) atau belum lunas (0)    |
| Jumlah Terlambat  | Seberapa sering pelanggan terlambat melakukan pembayaran              |

Pemilihan keenam fitur ini dilakukan karena mewakili dimensi perilaku yang penting, mulai dari intensitas transaksi, kepatuhan pembayaran, hingga potensi keterlambatan. Semua fitur yang dipilih memiliki skala numerik dan akan digunakan dalam proses standarisasi agar memiliki kontribusi yang seimbang dalam pembentukan klaster. Pemilihan fitur tersebut dituliskan dalam kode program 4.17 sebagai berikut:

**Kode Program 4.17** Standarisais Data

```
# Menyiapkan fitur untuk klasterisasi
fitur = dataset[['Jumlah Transaksi', 'Total
Pembayaran', 'Harga', 'Selisih', 'Status Pembayaran',
'Jumlah Terlambat']]

# Menskalakan fitur menggunakan RobustScaler
scaler = RobustScaler()
dataset_nrmlzd = scaler.fit_transform(fitur)
```

Pada penelitian ini digunakan metode *RobustScaler* dari pustaka *sklearn.preprocessing*, yang dipilih karena kemampuannya dalam mengurangi pengaruh nilai ekstrem atau *outlier*. Berbeda dengan metode lain seperti *MinMaxScaler* atau *StandardScaler*, *RobustScaler* menggunakan nilai median dan *interquartile range* (IQR) dalam proses standarisasinya. Hal ini membuat lebih tahan terhadap penyimpangan distribusi data yang tidak normal dan keberadaan *outlier*.

**Kode Program 4.18** Dataset Hasil Standarisasi

```
dataset_nrmlzd = pd.DataFrame(dataset_nrmlzd, columns
= fitur.columns)
dataset_nrmlzd
```

Dengan menjalankan baris kode seperti kode program 4.18, data yang sebelumnya telah distandarisasi kini disusun kembali dalam format yang terstruktur dan mudah dibaca. Setiap baris mewakili satu pelanggan, dan setiap kolom menunjukkan nilai fitur yang telah distandarisasi. Data ini selanjutnya akan digunakan sebagai input utama dalam proses klasterisasi menggunakan algoritma *X-Means*, karena sudah memenuhi syarat utama berupa skala data yang sebanding dan bebas dari outlier ekstrem yang merusak struktur klaster alami. Tabel 4.18 adalah dataset setelah datanya di standarisasi.

**Tabel 4.18.** Dataset Standarisasi

| <b>Jumlah Transaksi</b> | <b>Total Pembayaran</b> | <b>Harga</b>    | <b>Selisih</b> | <b>Status Pembayarann</b> | <b>Jumlah Terlambat</b> |
|-------------------------|-------------------------|-----------------|----------------|---------------------------|-------------------------|
| -1,125000               | 7,507830                | 96000000        | 0,000000<br>0  | 0                         | -0666667                |
| -1,125000               | 7,507830                | 96000000        | 0,000000<br>0  | 0                         | -0666667                |
| ...                     | ...                     | ...             | ...            | ...                       | ...                     |
| 1.375000                | 10.202948               | 13100000<br>0.0 | 0.00000<br>0   | 0.0                       | 2.583333                |

Berdasarkan hasil standarisasi yang ditampilkan pada data tabel 4.18, seluruh fitur numerik telah berhasil dirubah ke dalam skala yang seragam menggunakan metode *RobustScaler*. Nilai-nilai pada setiap fitur kini berada dalam kisaran yang lebih seimbang dan tidak lagi merepresentasikan nilai aslinya secara langsung, melainkan nilai relatif terhadap median dan *interquartile range* (IQR) masing-masing fitur. Tujuan dari transformasi ini adalah untuk menghilangkan dominasi fitur dengan skala besar dan mereduksi pengaruh *outlier* terhadap proses analisis selanjutnya.

Sebagai contoh, nilai pada kolom *Jumlah Transaksi* setelah standarisasi berkisar dari -1.125 hingga -0.083, menunjukkan bahwa sebagian besar pelanggan memiliki jumlah transaksi di bawah median. Hal yang sama juga terlihat pada kolom *Jumlah Terlambat*, di mana beberapa nilai negatif menandakan keterlambatan pembayaran yang berada di bawah nilai tengah distribusi. Sementara itu, kolom *Selisih* yang bernilai 0 setelah standarisasi menunjukkan bahwa pembayaran pelanggan tersebut sudah sesuai dengan harga properti, atau sudah lunas.

Secara keseluruhan, hasil standarisasi ini menunjukkan bahwa dataset telah berada dalam kondisi ideal untuk dilanjutkan ke tahap eksplorasi data lebih lanjut, analisis korelasi, pemilihan fitur akhir, serta proses pembentukan klaster menggunakan algoritma *X-Means*. Standarisasi yang dilakukan dengan tepat memberikan jaminan bahwa setiap fitur

berkontribusi secara adil dalam penentuan jarak antar data pada proses klasterisasi.

### 4.3. Explorasi Data Analisis

#### 4.3.1. Analisis Distribusi

Analisis distribusi dilakukan untuk memahami pola penyebaran data dari setiap fitur numerik yang telah distandarisasi. Pada tahap ini, visualisasi distribusi dibuat untuk lima fitur utama yang digunakan dalam klasterisasi, yaitu: *Jumlah Transaksi*, *Total Pembayaran*, *Harga*, *Selisih*, dan *Jumlah Terlambat*. Visualisasi dilakukan menggunakan grafik histogram yang dilengkapi dengan kurva kepadatan (*Kernel Density Estimation/KDE*) untuk melihat bentuk distribusi data secara lebih halus dan informatif.

Kode program 4.20 berikut digunakan untuk menghasilkan grafik distribusi:


#### Kode Program 4.20 Analisis Distribusi

```
# Pilih fitur-fitur yang ingin divisualisasikan
fitur_distr = ['Jumlah Transaksi', 'Total Pembayaran',
               'Harga', 'Selisih', 'Jumlah Terlambat']

# Buat plot distribusi untuk setiap fitur
plt.figure(figsize=(16, 10))
for i, feature in enumerate(fitur_distr):
    plt.subplot(2, 3, i + 1)
    sns.histplot(dataset_nrmlzd[feature], kde=True)
    plt.title(f'Distribusi {feature}')
plt.tight_layout()
plt.show()
```


Analisis ini penting karena memberikan pemahaman awal mengenai bentuk distribusi tiap fitur sebelum digunakan dalam proses klasterisasi. Dengan mengetahui karakteristik distribusi, peneliti dapat mengantisipasi apakah suatu fitur berpotensi mendominasi klaster atau menyebabkan bias. Distribusi yang tidak simetris atau memiliki outlier akan lebih aman digunakan setelah proses standarisasi, seperti yang telah dilakukan dalam

tahap sebelumnya menggunakan *RobustScaler*. Visualisasi ini juga menjadi dasar untuk mempertimbangkan fitur mana yang paling relevan untuk membentuk klaster yang bermakna.



**Gambar 4.1.** Distribusi Jumlah Transaksi


Plot gambar 4.1 menunjukkan sebaran nilai dari fitur *Jumlah Transaksi*. Terlihat bahwa data telah dinormalisasi (karena rentang nilainya mendekati nol). Distribusinya tampak agak simetris, namun masih menunjukkan adanya sedikit skew ke kanan, yang berarti ada beberapa pelanggan dengan jumlah transaksi yang lebih tinggi dari rata-rata.



**Gambar 4.2.** Distribusi Total Pembayaran


Distribusi pada gambar 4.2 menunjukkan nilai total pembayaran yang telah dinormalisasi. Terlihat bahwa data ini sangat right-skewed (condong ke kanan), artinya sebagian besar pelanggan memiliki total pembayaran

yang rendah, namun ada beberapa pelanggan dengan total pembayaran yang sangat tinggi (*outlier*). Hal ini umum terjadi dalam data keuangan atau penjualan.



**Gambar 4.3.** Distribusi Harga

Gambar 4.3 adalah fitur harga menunjukkan distribusi yang juga right-skewed dengan *outlier* yang cukup jauh dari pusat data. Ini mengindikasikan bahwa sebagian besar harga properti berada di kisaran tertentu, namun ada beberapa properti dengan harga yang sangat tinggi dibanding lainnya.




**Gambar 4.4.** Distribusi Selisih

Gambar 4.4 adalah fitur Selisih kemungkinan besar menggambarkan selisih antara pembayaran dengan jumlah tagihan. Sebagian besar nilai selisih berada di sekitar nol, yang menandakan bahwa mayoritas pelanggan membayar tepat sesuai jumlah tagihan. Namun, ada beberapa nilai di



sebelah kanan, mengindikasikan adanya kelebihan bayar, dan sedikit di sebelah kiri yang bisa menunjukkan kekurangan bayar.



**Gambar 4.5.** Distribusi Jumlah Terlambat

Distribusi pada gambar 4.5 menggambarkan seberapa sering pelanggan terlambat melakukan pembayaran. Mayoritas nilai berada di sekitar nol, yang berarti sebagian besar pelanggan jarang terlambat. Namun, terdapat ekor kanan yang panjang, menandakan adanya sejumlah kecil pelanggan yang sering terlambat membayar.

#### 4.3.2. Identifikasi *Outlier*

Setelah melakukan analisis distribusi terhadap fitur-fitur numerik, langkah selanjutnya adalah mengidentifikasi potensi *outlier* atau nilai pencilan dalam dataset yang telah distandarisasi. *Outlier* dapat memberikan pengaruh signifikan terhadap hasil klasterisasi, terutama dalam algoritma berbasis jarak seperti *X-Means*. Oleh karena itu, identifikasi awal terhadap keberadaan *outlier* sangat penting untuk memastikan kualitas segmentasi yang dihasilkan.


Untuk mendeteksi *outlier*, digunakan visualisasi *boxplot* terhadap lima fitur numerik, yaitu *Jumlah Transaksi*, *Total Pembayaran*, *Harga*, *Selisih*, dan *Jumlah Terlambat*. Visualisasi ini menggunakan script sesuai dengan kode program 4.21:

|                                          |
|------------------------------------------|
| <b>Kode Program 4.21</b> Deteksi Outlier |
|------------------------------------------|

|                                       |
|---------------------------------------|
| # Box plot untuk setiap fitur numerik |
|---------------------------------------|


```
plt.figure(figsize=(16, 10))
for i, feature in enumerate(fitur_distr):
    plt.subplot(2, 3, i + 1)
    sns.boxplot(y=dataset_nrmlzd[feature])
    plt.title(f'Box Plot untuk {feature}')
plt.tight_layout()
plt.show()
```

Berikut adalah boxplot hasil dari deteksi *outlier*.



**Gambar 4.6.** Box Plot Jumlah Transaksi


Plot gambar 4.6 menunjukkan distribusi data fitur *Jumlah Transaksi* yang telah dinormalisasi. Data berada dalam rentang yang relatif seimbang, dan tidak tampak adanya outlier yang mencolok. Median berada di sekitar nol, menunjukkan distribusi yang cukup simetris.



**Gambar 4.7.** Box Plot Total Pembayaran


Gambar 4.7 memperlihatkan banyak *outlier* di bagian atas dan bawah. Artinya, ada sejumlah pelanggan yang melakukan pembayaran dengan nilai

yang jauh lebih tinggi atau lebih rendah dari mayoritas data lainnya. Hal ini dapat mengindikasikan variasi ekstrem dalam nominal pembayaran, yang perlu dikaji lebih lanjut, apakah merupakan kesalahan data atau memang variasi alami.



**Gambar 4.8.** Box Plot Harga


*Boxplot* fitur Harga pada gambar 4.8 menunjukkan adanya banyak outlier ekstrem di atas. Ini menandakan bahwa terdapat properti dengan harga jauh lebih tinggi dibandingkan dengan mayoritas lainnya. Fenomena ini umum terjadi di data harga properti, di mana terdapat unit-unit premium yang secara alami berada di luar distribusi normal.



**Gambar 4.9.** Box Plot Selisih

Gambar 4.9 adalah fitur *Selisih* (kemungkinan selisih antara total pembayaran dan total tagihan) menunjukkan bahwa sebagian besar nilai

berada dekat dengan nol (yang berarti pembayaran sesuai tagihan), tetapi terdapat beberapa outlier di atas. Ini menunjukkan ada pelanggan yang melakukan pembayaran lebih besar dari tagihan yang seharusnya (overpayment), dan perlu ditelusuri apakah ini merupakan error atau kebijakan sistem.



**Gambar 4.10.** Box Plot Jumlah terlambat

Gambar 4.10 memperlihatkan bahwa sebagian besar pelanggan memiliki jumlah keterlambatan rendah, dengan banyak nilai mendekati nol. Namun, terlihat beberapa *outlier* yang menunjukkan pelanggan dengan frekuensi keterlambatan tinggi. Ini penting untuk dianalisis lebih lanjut karena bisa menjadi indikator pelanggan yang berisiko tinggi.

Keberadaan *outlier* ini menunjukkan bahwa dataset memiliki keragaman perilaku pelanggan yang cukup tinggi, terutama dalam hal jumlah transaksi, keterlambatan pembayaran, dan total nilai transaksi. Meskipun metode *RobustScaler* telah digunakan sebelumnya untuk meminimalkan dampak *outlier* terhadap proses standarisasi, visualisasi ini tetap berguna untuk mendeteksi karakteristik khusus dari pelanggan-pelanggan yang nantinya bisa membentuk klaster tersendiri.

#### 4.3.3. Korelasi *Pearson*

Analisis korelasi dilakukan untuk mengetahui sejauh mana hubungan linier antar fitur numerik yang digunakan dalam proses klasterisasi. Dalam penelitian ini, digunakan metode *Pearson Correlation* yang menghitung

kekuatan dan arah hubungan linier antar fitur numerik, dengan nilai koefisien berkisar antara  $-1$  hingga  $1$ . Nilai mendekati  $+1$  menandakan korelasi positif kuat, mendekati  $-1$  menunjukkan korelasi negatif kuat, dan mendekati  $0$  menunjukkan tidak ada korelasi linier yang signifikan.

Script pada kode program 4.22 berikut digunakan untuk menghitung dan memvisualisasikan korelasi:

**Kode Program 4.22** Korelasi Pearson


```
# Matriks korelasi menggunakan metode Pearson
correlation_matrix = dataset_nrmlzd.corr(method='pearson')

# Visualisasi matriks korelasi
plt.figure(figsize=(10, 8))
sns.heatmap(correlation_matrix, annot=True,
            cmap='coolwarm', fmt=".2f", linewidths=.5)
plt.title('Matriks Korelasi Fitur (Pearson)')
plt.show()
```

Dari matriks gambar 4.11, terlihat bahwa terdapat korelasi yang sangat kuat antara fitur *Jumlah Transaksi* dan *Jumlah Terlambat* dengan nilai  $0.89$ . Ini mengindikasikan bahwa semakin banyak transaksi yang dilakukan oleh pelanggan, semakin besar kemungkinan mereka mengalami keterlambatan pembayaran. Selain itu, terdapat korelasi positif yang cukup kuat antara *Total Pembayaran* dan *Harga* sebesar  $0.84$ , yang menunjukkan bahwa semakin tinggi harga properti, maka semakin besar pula total pembayaran yang dilakukan.

Sebaliknya, fitur *Selisih* menunjukkan korelasi negatif dengan beberapa fitur lainnya, terutama terhadap *Status Pembayaran* ( $-0.69$ ) dan *Jumlah Transaksi* ( $-0.44$ ). Hal ini dapat diartikan bahwa semakin besar nilai selisih (misalnya, selisih antara jumlah yang seharusnya dibayar dan yang dibayarkan), maka status pembayaran cenderung menurun (misalnya, menjadi tidak lunas), serta jumlah transaksi juga cenderung berkurang.

Adapun *Status Pembayaran* memiliki korelasi positif dengan *Jumlah Transaksi* (0.35) dan *Total Pembayaran* (0.39), yang berarti pelanggan dengan transaksi dan pembayaran yang tinggi cenderung memiliki status pembayaran yang lebih baik. Secara keseluruhan, analisis korelasi ini membantu memahami hubungan antar fitur dan dapat menjadi landasan penting dalam membangun model prediktif atau segmentasi pelanggan.



**Gambar 4.11.** Korelasi Pearson

Analisis korelasi ini penting dilakukan sebelum proses klusterisasi untuk mengidentifikasi potensi multikolinearitas antar fitur. Fitur-fitur dengan korelasi sangat tinggi mungkin mengandung informasi yang redundan atau berlebihan, sehingga dapat dipertimbangkan untuk dihilangkan atau disederhanakan agar tidak mengganggu struktur alami kluster.

#### 4.3.4. Menghitung *Variance Inflation Factor* (VIF)

Setelah dilakukan analisis korelasi menggunakan Pearson, langkah lanjutan yang dilakukan dalam penelitian ini adalah mengevaluasi tingkat multikolinearitas antar fitur menggunakan metode *Variance Inflation Factor* (VIF). VIF digunakan untuk mengukur sejauh mana suatu fitur dapat

dijelaskan oleh fitur lainnya. Nilai VIF yang tinggi menunjukkan bahwa fitur tersebut memiliki korelasi tinggi dengan satu atau lebih fitur lainnya, yang berisiko menyebabkan redundansi informasi dalam proses klasterisasi. Script pada kode program 4.23 berikut digunakan untuk menghitung VIF:

**Kode Program 4.23** Perhitungan *Variance Inflation Factor*

```
# Hitung VIF untuk setiap fitur
vif_data = pd.DataFrame()
vif_data["Fitur"] = dataset_nrmlzd.columns
vif_data["VIF"] = [variance_inflation_factor(dataset_nrmlzd.values, i)
                    for i in range(dataset_nrmlzd.shape[1])]

print(vif_data)
```

Berdasarkan hasil analisis korelasi *Pearson* dan perhitungan VIF, ditemukan bahwa beberapa fitur menunjukkan korelasi yang sangat tinggi satu sama lain serta nilai VIF yang jauh melebihi ambang toleransi multikolinearitas ( $>10$ ). Sebagai contoh, fitur *Harga* dan *Total Pembayaran* memiliki nilai VIF sebesar 833,87 dan 829,78 seperti yang tertera pada tabel 4.19, yang mengindikasikan tingkat multikolinearitas yang sangat tinggi dan berpotensi memberikan dampak negatif terhadap proses klasterisasi.

**Tabel 4.19.** Perhitungan VIF

| Fitur             | VIF        |
|-------------------|------------|
| Jumlah Transaksi  | 5.243517   |
| Total Pembayaran  | 829.783001 |
| Harga             | 833.869968 |
| Selisih           | 342.294534 |
| Status Pembayaran | 2.022132   |
| Jumlah terlambat  | 5.442761   |

Oleh karena itu, fitur-fitur yang dipilih untuk digunakan dalam proses klasterisasi adalah fitur yang dianggap bebas dari permasalahan korelasi tinggi atau multikolinearitas, serta mampu merepresentasikan

perilaku pelanggan. Fitur-fitur tersebut disaring menjadi 2, yaitu: Jumlah Terlambat dan Status Pembayaran. Pada tabel 4.20 terlihat bahwa setelah dilakukan drop fitur yang memiliki korelasi tinggi, hasil perhitungan VIF pada 2 fitur tersebut tidak tinggi. Hasil VIF memberikan gambaran tambahan setelah analisis korelasi *Pearson*, guna memastikan bahwa fitur-fitur yang digunakan dalam proses klasterisasi bersifat independen secara informasi dan tidak menyebabkan distorsi dalam pemetaan klaster.

**Tabel 4.20.** Perhitungan VIF Setelah Diatasi

| Fitur             | VIF      |
|-------------------|----------|
| Status Pembayaran | 1.096042 |
| Jumlah Terlambat  | 1.096042 |

Dengan demikian, analisis VIF berperan sebagai salah satu langkah validasi penting dalam tahapan seleksi fitur sebelum dilakukan pemodelan klasterisasi dengan algoritma *X-Means*.

#### 4.4. Implementasi *X-Means*

Proses implementasi algoritma *X-Means* dalam penelitian ini bertujuan untuk melakukan segmentasi pelanggan berdasarkan karakteristik perilaku pembayaran mereka. *X-Means* dipilih karena memiliki keunggulan dalam menentukan jumlah klaster optimal dengan komputasi yang cepat. Hal ini memungkinkan pembentukan klaster yang lebih representatif terhadap pola distribusi alami dari data pelanggan.

Langkah awal dalam proses ini adalah melakukan inisialisasi pusat klaster awal secara acak menggunakan *random\_center\_initializer*, seperti pada kode program 4.24.

**Kode Program 4.24** Implementasi Model *X-Means*

```
initial_centers =
random_center_initializer(fitur_klaster_np,
2).initialize()
```

Pusat-pusat awal ini kemudian digunakan sebagai masukan untuk model *X-Means*, yang dipanggil melalui parameter *kmin*=2 dan *kmax*=3. Ini berarti model



diberi batas minimal dua dan maksimal tiga kluster sesuai dengan kode program 4.25:

| Kode Program 4.25 Metode <i>X-Means</i>                                                                    |
|------------------------------------------------------------------------------------------------------------|
| <pre>xmeans_model = xmeans(fitur_klaster_np, initial_centers, kmin=2, kmax=3) xmeans_model.process()</pre> |

Setelah proses klasterisasi selesai, hasil pengelompokan disimpan dalam fitur clusters, dan koordinat pusat dari masing-masing kluster disimpan dalam cluster\_centers. Jumlah kluster optimal yang terbentuk kemudian dihitung menggunakan len(clusters) dan disimpan dalam fitur optimal\_k. kode program 4.26 adalah script untuk menampilkan optimal k:

| Kode Program 4.26 Optimal K                                                                                                        |
|------------------------------------------------------------------------------------------------------------------------------------|
| <pre>clusters = xmeans_model.get_clusters() cluster_centers = xmeans_model.get_centers() optimal_k = len(clusters) optimal_k</pre> |

Output dari tahapan ini memberikan informasi penting mengenai struktur segmentasi pelanggan yang paling sesuai berdasarkan data historis pembayaran. Dalam penelitian ini, jumlah kluster optimal yang terbentuk adalah sebanyak 3 kluster, yang berarti terdapat 3 kelompok pelanggan yang memiliki pola pembayaran berbeda berdasarkan fitur yang dianalisis.

Selain dengan komputasi penelitian ini mencoba melakukan perhitungan secara manual menggunakan data yang sama dengan rumus *X-Means*. Tabel 4.21 adalah dataset yang digunakan sebagai contoh data perhitungan manual menggunakan *X-Means* berdasarkan rumus perhitungan 2.1.

**Tabel 4.21.** Dataset

|     | Jumlah Terlambat | Status Pembayaran |
|-----|------------------|-------------------|
| 0   | 0                | 1                 |
| 1   | 0                | 1                 |
| ... | ...              | ...               |
| 385 | 39               | 1                 |

Fitur yang digunakan adalah Jumlah Terlambar dan Status Pembayaran dengan data sesuai pada tabel 4.21. Tahapan pertama, dilakukan inisialisasi  $k=1$

- $\mu = \left( \frac{0+0+39}{3}, \frac{1+1+1}{3} \right) = (13,1)$

Selanjutnya menghitung SSE (*Sum of Squared Errors*),

- $(0,1) = (0 - 13)^2 + (1 - 1)^2 = 169$
- $(0,1) = 169$
- $(39,1) = (39 - 13)^2 + (1 - 1)^2 = 676$
- $SSE = 169 + 169 + 676 = 1014$

Menghitung varians:

- $\sigma^2 = \frac{SSE}{n} = \frac{1014}{3} = 338$

Menghitung log-likelihood:

- $$\begin{aligned} LL &= -\frac{3 \times 2}{2} \ln(2\pi \times 338) - \frac{1014}{2 \times 338} \\ &= -3 \times \ln(2124) - \frac{1014}{676} \\ &= 3 \times 7,6609 - 1,5 \\ &= -24,4828 \end{aligned}$$

Perhitungan BIC:

- $$\begin{aligned} BIC &= -24,4828 - \frac{3}{2} \ln(3) \\ &= -24,4828 - 1,6479 \\ &= -26,1307 \end{aligned}$$

Setelah menemukan BIC pertama pada  $k=1$ , selanjutnya menghitung kembali seperti sebelumnya dengan inisialisasi  $k=2$ :

- Klaster 1 =  $\{(0,1), (01)\}$  *centroidnya* (0,1)
- Klaster 2 =  $\{(39,1)\}$  *centroidnya* (39,1)

Perhitungan SSE per klaster:

- Klaster 1 = kedua titik data identic dengan *centroid* maka,  $SSE_1 = 0$
- Klaster 2 = memiliki satu titik data yang sama dengan *centroidnya* maka,  $SSE_2 = 0$
- $SSE_{total} = 0$

Jika SSE total didapatkan nilai 0 maka varians mendapatkan hasil 0, sehingga untuk perhitungan log-likelihoodnya menjadi tak hingga. Maka memakai permisalan regularisasi kecil, yaitu:

- $\sigma^2 = \varepsilon$ , misal  $\varepsilon = 10^{-6}$

Log-likelihood dengan SSE = 0 dan varians =  $\varepsilon$ , maka:

$$\begin{aligned} \bullet \quad L &= -\frac{nd}{2} \ln(2\pi\varepsilon) - \frac{0}{2\varepsilon} = -3 \times \ln(2\pi\varepsilon) \\ &= -3 \times \ln(2\pi \times 10^{-6}) \\ &= -3 \times \ln(6,283 \times 10^{-6}) \\ &= -3 \times (\ln 6,283 - 13,8155) \\ &= 35,9329 \end{aligned}$$

Perhitungan BIC:

$$\begin{aligned} \bullet \quad \text{BIC} &= 35,9329 - \frac{5}{2} \ln(3) \\ &= 35,9329 - 2,5 \times 1,0986 \\ &= 33,1864 \end{aligned}$$

Keputusan *X-Means* antar BIC:

- BIC (k=1) = -26,1307
- BIC (k=2) = 33,1864

Karena BIC (k=2) lebih besar daripada BIC (k=1) maka split kluster diterima dan kluster optimalnya berjumlah 2. Maka;

- Kluster 1: (0,1), (0,1)
- Kluster 2: (39,1)

#### 4.5. Evaluasi Model *X-Means*

Penelitian ini, menggunakan tiga metrik evaluasi, yaitu *Silhouette Score*, *Davies-Bouldin Index* (DBI), dan *Calinski-Harabasz Index* (CHI). Ketiga metrik ini memiliki pendekatan yang berbeda namun saling melengkapi untuk menilai performa segmentasi yang dihasilkan oleh algoritma *X-Means*. Kode program 4.27 adalah script untuk menghitung evaluasi metrik *Silhouette Score*.

**Kode Program 4.27 Silhouette Score**

```
# Menghitung Silhouette Score
silhouette_avg = silhouette_score(fitur_klaster_np,
dataset['Klaster'])
print(f"Silhouette Score: {silhouette_avg:.3f}")
```

Evaluasi *Silhouette score* mendapatkan nilai 0,606, menunjukkan bahwa hasil klasterisasi memiliki kualitas pemisahan yang baik dan setiap klaster cukup terpisah jelas dari klaster lainnya. Kode program 4.28 adalah kode script untuk evaluasi DBI.

**Kode Program 4.28 DBI**

```
# Menghitung Dbi
dbi_score = davies_bouldin_score(fitur_klaster_np,
dataset['Klaster'])
print(f"Dbi Score: {dbi_score:.3f}")
```

Nilai DBI sebesar 0,538 yang didapatkan tergolong cukup baik, menunjukkan bahwa klaster-klaster yang terbentuk memiliki jarak antar klaster. Hal ini memperkuat hasil dari *Silhouette Score* sebelumnya. Evaluasi metrik ketiga menggunakan *Calinski Harabaz* kode script tertera pada kode program 4.29.

**Kode Program 4.29 Calinski Harabazs**

```
# Menghitung Calinski Harabasz
ch_score = calinski_harabasz_score(fitur_klaster_np,
dataset['Klaster'])
print(f"ch Score: {ch_score:.3f}")
```

Penelitian ini menghasilkan nilai *Calinski-Harabasz* sebesar 472.924, dapat dibilang cukup tinggi, menandakan bahwa klaster-klaster memiliki pengelompokan data yang terpisah.

Ketiga metrik evaluasi secara konsisten menunjukkan bahwa hasil klasterisasi yang dihasilkan oleh algoritma *X-Means* dalam penelitian ini memiliki kualitas yang baik. Nilai *Silhouette Score* yang cukup tinggi, DBI yang rendah, dan CHI yang cukup baik mengindikasikan bahwa pemodelan segmentasi yang dibangun mampu merepresentasikan struktur data dengan akurat.

#### 4.6. Perbandingan Waktu Komputasi *X-Means* dan *K-Means*

Penelitian ini membandingkan efisiensi komputasi antara algoritma *X-Means* dengan *K-Means*. Perbandingan ini dilakukan untuk melihat seberapa optimal *X-Means* dalam memproses data pembayaran pelanggan dibandingkan metode baseline yang lebih umum digunakan, yaitu *K-Means*. Tabel 4.22 menunjukkan perbandingan komputasi antara *X-Means* dan *K-Means*.

**Tabel 4.22.** Perbandingan Waktu Komputasi

| Metode         | Waktu Komputasi (s) |
|----------------|---------------------|
| <i>X-Means</i> | 0.0243              |
| <i>K-Means</i> | 0.1967              |

Berdasarkan tabel 4.22, *X-Means* mampu menyelesaikan proses klusterisasi dalam waktu yang lebih singkat (0,0309 detik) dibandingkan *K-Means* (0,1625 detik). Hal ini menunjukkan bahwa *X-Means* bekerja lebih efisien pada dataset yang digunakan. Perbedaan waktu ini muncul karena *X-Means* memiliki mekanisme yang secara dinamis menyesuaikan jumlah kluster melalui evaluasi *Bayesian Information Criterion* (BIC). Dengan cara ini, proses pencarian jumlah kluster yang sesuai tidak perlu dilakukan secara manual seperti pada *K-Means*. Dengan demikian, hasil penelitian ini semakin menguatkan alasan pemilihan *X-Means* yang memiliki keunggulan kecepatan komputasi yang lebih baik dibandingkan metode pembanding.

#### 4.7. Interpretasi Kluster

Setelah proses klusterisasi dilakukan menggunakan algoritma *X-Means* dan didapatkan hasil optimal sejumlah 3 kluster, langkah selanjutnya adalah melakukan interpretasi terhadap masing-masing kluster guna memahami karakteristik pelanggan yang tergabung di dalamnya. Interpretasi hasil *Clustering* diperoleh dengan mengombinasikan analisis statistik deskriptif setiap kluster serta pendekatan berbasis aturan (*rule-based*) yang ditentukan sesuai karakteristik data pembayaran. Hasil analisis *Clustering* menghasilkan tiga kelompok pelanggan yang memiliki karakteristik berbeda. Dengan interpretasi setiap klasternya adalah;

Klaster 0 terdiri dari 160 data atau sekitar 41,5% dari total populasi. Rata-rata keterlambatan pembayaran pada kelompok ini adalah 4,2 hari dengan tingkat penyelesaian pembayaran sebesar 0%. Karakteristik pelanggan dalam cluster ini cenderung berada pada segmen properti dengan harga menengah ke bawah. Tingkat keterlambatan pembayaran cukup bervariasi, namun seluruh pelanggan dalam kelompok ini masih berstatus belum melunasi kewajibannya. Oleh karena itu, klaster ini dapat dikategorikan sebagai pelanggan dengan risiko rendah hingga menengah. Strategi yang sesuai untuk segmen ini adalah dengan melakukan monitoring rutin, menyediakan program edukasi finansial, memberikan fleksibilitas dalam skema pembayaran, serta menerapkan sistem peringatan dini untuk mencegah keterlambatan yang lebih besar.

Klaster 1 beranggotakan 90 data atau 23,3% dari total. Klaster ini menunjukkan rata-rata keterlambatan sebesar 2,6 hari dengan tingkat pembayaran 100%. Segmen ini dapat dikategorikan sebagai pelanggan premium dengan risiko rendah. Mereka umumnya membeli properti dengan harga tinggi dan menunjukkan perilaku pembayaran yang sangat baik, ditandai dengan keterlambatan yang rendah dan tingkat pelunasan yang sempurna. Strategi yang dapat diterapkan pada cluster ini adalah memberikan layanan premium yang lebih personal, mengembangkan program loyalitas eksklusif, memberikan kemudahan dalam akses produk finansial lain, serta menjaga hubungan jangka panjang dengan pelanggan.


Klaster 2 mencakup 136 data atau 35,2% dari total. Klaster ini memiliki rata-rata keterlambatan pembayaran yang cukup tinggi, yaitu 14,8 hari, dengan tingkat penyelesaian pembayaran sebesar 96,3%. Segmen ini berada pada kategori pelanggan dengan risiko tinggi. Mereka umumnya berasal dari kelompok properti dengan harga menengah ke atas, namun menunjukkan kecenderungan keterlambatan pembayaran yang signifikan. Oleh karena itu, pelanggan dalam klaster ini membutuhkan perhatian khusus. Strategi yang relevan adalah melakukan penagihan intensif dan terstruktur, memberikan opsi restrukturisasi pembayaran, melakukan analisis lebih mendalam mengenai penyebab keterlambatan, hingga mempertimbangkan langkah hukum apabila diperlukan.

Secara keseluruhan, ketiga cluster ini memberikan gambaran segmentasi risiko pelanggan. klaster 0 memiliki profil pelanggan yang berisiko rendah tetapi tetap

perlu adanya monitoring dan pencegahan, klaster 1 menjadi peluang untuk strategi retensi dan *cross-selling* karena memiliki profil pelanggan potensial, sedangkan klaster 2 membutuhkan pantauan khusus untuk penagihan karena memiliki profil pelanggan yang berisiko tinggi.

#### 4.8. Visualisasi Klaster

Untuk memperoleh gambaran awal mengenai distribusi anggota pada masing-masing klaster, dilakukan visualisasi dalam bentuk diagram batang. Visualisasi ini bertujuan untuk menunjukkan jumlah data (anggota) yang tergolong dalam tiap klaster hasil proses klasterisasi. Dengan melihat jumlah anggota per klaster, analisis dapat difokuskan pada klaster yang dominan maupun klaster minoritas, sehingga strategi analisis lanjutan atau pengambilan keputusan dapat disesuaikan dengan karakteristik kelompok tersebut.




**Gambar 4.12.** Anggota Klaster

Berdasarkan hasil klasterisasi yang ditunjukkan pada gambar 4.12, diperoleh 3 klaster dengan jumlah anggota yang bervariasi. Klaster 0 merupakan klaster dengan jumlah anggota terbanyak, yaitu sebanyak 160 pelanggan. Hal ini menunjukkan bahwa karakteristik yang dimiliki oleh klaster ini merupakan pola yang paling umum ditemukan dalam dataset.

Klaster 2 menempati posisi kedua dengan 136 anggota, diikuti oleh klaster 1 dengan 90 anggota. Distribusi jumlah anggota yang relatif tidak merata ini mengindikasikan adanya perbedaan proporsi karakteristik pelanggan, di mana sebagian besar memiliki pola pembayaran yang mirip (klaster 0 dan klaster 2), sementara sebagian lainnya memiliki ciri yang lebih khusus (klaster 1).

Perbedaan proporsi ini penting untuk diperhatikan karena meskipun klaster dengan anggota lebih sedikit seperti klaster 1 bukan mayoritas, kelompok ini tetap berpotensi mencerminkan karakteristik pelanggan dengan risiko tertentu atau nilai strategis bagi perusahaan. Oleh karena itu, strategi penanganan pelanggan sebaiknya disesuaikan dengan profil masing-masing klaster agar lebih efektif dan tepat sasaran.



**Gambar 4.13.** Jumlah Pelanggan Berdasarkan Klaster dan Status Pembayaran


Gambar plot 4.13 menunjukkan distribusi jumlah pelanggan berdasarkan klaster dan status pembayaran (lunas dan belum lunas). Dari grafik terlihat bahwa klaster pertama sepenuhnya terdiri dari pelanggan dengan status *belum lunas*, yang menandakan kelompok ini memiliki tingkat risiko yang tinggi dari sisi kepatuhan pembayaran. Sebaliknya, klaster kedua sepenuhnya beranggotakan pelanggan dengan status *lunas*, sehingga dapat dikategorikan sebagai kelompok dengan perilaku pembayaran yang sangat baik dan berisiko rendah.

Pada klaster ketiga, sebagian besar pelanggan juga berstatus *lunas* dengan hanya sedikit anggota yang belum menyelesaikan kewajibannya. Hal ini menunjukkan bahwa meskipun secara umum klaster ini cukup sehat, tetap terdapat potensi risiko yang perlu diperhatikan.

Visualisasi ini memberikan gambaran yang jelas mengenai profil masing-masing klaster berdasarkan perilaku pembayaran. Klaster dengan dominasi *belum lunas* perlu mendapatkan perhatian khusus, sedangkan klaster dengan dominasi *lunas* dapat dijadikan prioritas untuk program retensi dan loyalitas pelanggan. Gambar 4.14 menunjukkan hasil visualisasi klaster menggunakan algoritma *t*-



*Distributed Stochastic Neighbor Embedding (t-SNE)*, sebuah metode reduksi dimensi non-linear yang digunakan untuk memproyeksikan data berdimensi tinggi ke dalam ruang dua dimensi. Setiap titik pada grafik merepresentasikan satu pelanggan, dengan pewarnaan berbeda untuk menandai klaster yang terbentuk.



**Gambar 4.14.** t-SNE Persebaran Klaster

Dari gambar 4.14, visualisasi ini dapat diamati bahwa ketiga klaster (0 berwarna biru, 1 berwarna oranye, dan 2 berwarna hijau) membentuk kelompok yang cukup jelas meskipun terdapat sedikit area tumpang tindih. Klaster 0 cenderung terkonsentrasi di sisi kiri bawah grafik, klaster 1 berada di bagian atas, sedangkan klaster 2 tersebar di bagian kanan.

Pemisahan ini mengindikasikan bahwa algoritma *X-Means* mampu mengelompokkan pelanggan berdasarkan kesamaan pola pembayaran mereka dengan cukup baik. Adanya jarak antar kelompok menunjukkan perbedaan karakteristik yang cukup signifikan, sementara titik-titik yang berada dekat batas antar klaster dapat mencerminkan pelanggan dengan karakteristik campuran atau transisi. Secara keseluruhan, visualisasi *t-SNE* ini memberikan validasi visual terhadap hasil klasterisasi, menunjukkan bahwa segmen pelanggan memiliki pola yang dapat dibedakan, sehingga dapat mendukung proses interpretasi lebih lanjut untuk strategi manajemen pelanggan.

#### 4.9. Kontribusi dan Pemanfaatan, Rekomendasi, serta Implementasi Strategi

Untuk mendukung hasil analisis klasterisasi yang telah diperoleh, diperlukan rekomendasi strategi yang dapat menjadi acuan bagi perusahaan dalam mengoptimalkan pengelolaan pelanggan. Rekomendasi ini disusun dengan mempertimbangkan karakteristik masing-masing klaster serta sistem pembayaran *inhouse* syariah yang diterapkan oleh perusahaan. Dengan demikian, strategi yang dihasilkan diharapkan tidak hanya mampu meminimalkan risiko keterlambatan pembayaran, tetapi juga meningkatkan kepuasan dan loyalitas pelanggan sesuai dengan prinsip syariah. Berikut adalah tabel 4.23 yang menyajikan pemanfaatan hasil penelitian dan dapat digunakan perusahaan untuk mendukung pengambilan keputusan strategis.

**Tabel 4.23.** Kontribusi dan Pemanfaatan Strategi

| Klaster                                       | Kontribusi & Pemanfaatan Strategis                                                                                                                                                                                                                                                                                                                                       |
|-----------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Klaster 0</b><br>(Risiko Rendah–Menengah)  | <ul style="list-style-type: none"> <li>▪ Dasar perancangan akad fleksibel.</li> <li>▪ Indikator kebutuhan <i>rescheduling</i>.</li> <li>▪ Identifikasi pelanggan yang perlu edukasi finansial.</li> <li>▪ Proyeksi arus kas lebih akurat meski tanpa bunga.</li> <li>▪ Penyesuaian akad sesuai kondisi pelanggan.</li> <li>▪ Pencegahan risiko keterlambatan.</li> </ul> |
| <b>Klaster 1</b><br>(Premium – Risiko Rendah) | <ul style="list-style-type: none"> <li>▪ Segmen paling sehat &amp; disiplin.</li> <li>▪ Potensial untuk produk premium syariah.</li> <li>▪ Basis loyalitas untuk <i>cross-selling</i> produk syariah baru.</li> <li>▪ Target produk investasi syariah (kavling/ruko).</li> </ul>                                                                                         |
| <b>Klaster 2</b><br>(Risiko Tinggi)           | <ul style="list-style-type: none"> <li>▪ Perlunya musyawarah penyelesaian.</li> <li>▪ Dasar restrukturisasi tanpa denda.</li> <li>▪ Acuan edukasi calon pembeli baru.</li> <li>▪ Memperkuat klausul akad agar lebih jelas.</li> <li>▪ Data filter seleksi calon pembeli.</li> <li>▪ Strategi pemulihan pembayaran.</li> </ul>                                            |

|  |                                                                                                                                                                            |
|--|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|  | <ul style="list-style-type: none"> <li>• Dapat dimanfaatkan untuk analisis penyebab keterlambatan berulang atau gagal bayar supaya tidak terulang di akad baru.</li> </ul> |
|--|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

Tabel 4.24. berikut adalah tabel yang berisi rekomendasi strategi yang disusun berdasarkan pola pembayaran pelanggan hasil segmentasi.

**Tabel 4.24. Rekomendasi Strategi**

| Klaster                                       | Rekomendasi Strategi                                                                                                                                                                                                               |
|-----------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Klaster 0</b><br>(Risiko Rendah–Menengah)  | <ul style="list-style-type: none"> <li>• <i>Monitoring</i> rutin &amp; edukasi finansial syariah.</li> <li>• Skema cicilan fleksibel berbasis musyawarah.</li> <li>• <i>Early warning system</i> tanpa penalti.</li> </ul>         |
| <b>Klaster 1</b><br>(Premium – Risiko Rendah) | <ul style="list-style-type: none"> <li>• Program loyalitas syariah.</li> <li>• Penawaran produk investasi premium.</li> <li>• <i>Relationship maintenance</i> jangka panjang.</li> </ul>                                           |
| <b>Klaster 2</b><br>(Risiko Tinggi)           | <ul style="list-style-type: none"> <li>• Pendekatan musyawarah.</li> <li>• Restrukturisasi pembayaran (akad ulang).</li> <li>• Evaluasi profil risiko.</li> <li>• Pendampingan khusus untuk mencegah gagal bayar total.</li> </ul> |

Tabel 4.25 berikut adalah tabel penggambaran implementasi nyata sesuai dengan sistem *inhouse* syariah yang dapat diterapkan perusahaan.

**Tabel 4.25. Contoh Implementasi Nyata**

| Klaster                                       | Contoh Implementasi Nyata                                                                                                                                                                                                                                    |
|-----------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Klaster 0</b><br>(Risiko Rendah–Menengah)  | <ul style="list-style-type: none"> <li>• Program <i>Reminder Syariah</i> (notifikasi via WA/SMS sebelum jatuh tempo).</li> <li>• <i>Workshop</i> “Perencanaan Keuangan Islami”.</li> <li>• Dashboard pelanggan untuk melihat progress cicilan.</li> </ul>    |
| <b>Klaster 1</b><br>(Premium – Risiko Rendah) | <ul style="list-style-type: none"> <li>• Program <i>Loyalty Card Syariah</i> (prioritas pembelian unit baru tanpa DP).</li> <li>• Penawaran kavling investasi berbasis akad murabahah.</li> <li>• Testimoni pelanggan sebagai <i>brand trust</i>.</li> </ul> |

|                                     |                                                                                                                                                                                                                                                                                 |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Klaster 2</b><br>(Risiko Tinggi) | <ul style="list-style-type: none"> <li>▪ Program <i>Restructuring Clinic</i> (sesi musyawarah antara perusahaan &amp; pelanggan).</li> <li>▪ Skema <i>akad ulang</i> dengan cicilan lebih ringan.</li> <li>▪ Edukasi calon pembeli baru tentang komitmen pembayaran.</li> </ul> |
|-------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|

Rekomendasi strategi yang tersusun dalam tabel di atas menunjukkan keterkaitan langsung antara hasil segmentasi pelanggan dengan penerapan strategi bisnis berbasis inhouse syariah. Dengan pendekatan ini, perusahaan tidak hanya mampu meminimalkan risiko keterlambatan pembayaran, tetapi juga memperkuat hubungan jangka panjang dengan pelanggan melalui solusi yang adil, fleksibel, dan berorientasi pada keberlanjutan.

#### 4.10. Deployment

Setelah proses pengolahan data, analisis, serta klasterisasi dilakukan, aplikasi Propalysis dikembangkan dan di *deploy* untuk memudahkan pengguna dalam mengakses hasil analisis secara interaktif. Proses *deployment* ini dilakukan dengan menggunakan platform yang mendukung integrasi *machine learning* model ke dalam antarmuka pengguna berbasis web. Dengan tampilan antarmuka yang intuitif, pengguna dapat mengeksplorasi informasi terkait klaster pelanggan, karakteristik pembayaran, dan strategi yang dapat dilakukan berdasarkan hasil segmentasi. Gambar 4.15 berikut ini adalah tampilan antarmuka dari aplikasi Propalysis:




**Gambar 4.15.** Halaman Utama

Tampilan 4.15 menunjukkan antarmuka utama dari aplikasi Propalysis yang terdiri dari beberapa menu navigasi seperti Tentang Aplikasi, Data, dan Analisis &

Klasterisasi. Di bagian utama, pengguna dapat melihat deskripsi aplikasi, tujuan, serta fitur yang tersedia. Dengan sistem ini, pihak manajemen dapat dengan mudah memonitor pola pembayaran pelanggan serta membuat keputusan strategis berbasis data yang telah diproses menggunakan algoritma *X-Means*.

*Website* ini telah dioptimalkan untuk mendukung visualisasi hasil analisis serta memberikan insight yang dapat langsung ditindaklanjuti dalam proses bisnis. Dengan demikian, deployment aplikasi ini merupakan tahapan penting yang menjembatani hasil analisis data dengan pengambilan keputusan nyata di lapangan.

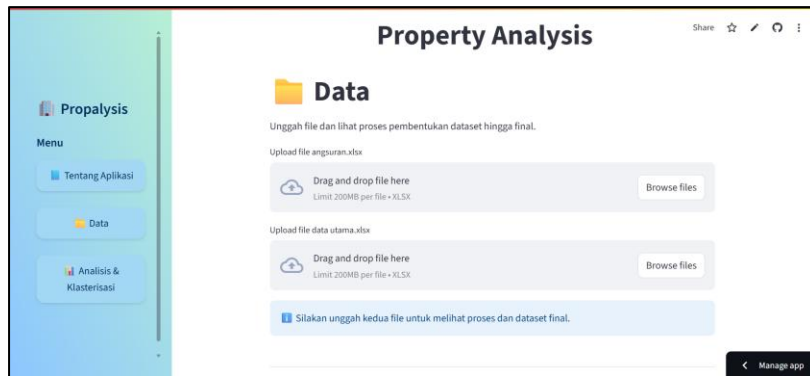


**Gambar 4.16.** Fitur Web

Ada tiga fitur utama pada website Propalysis yang dirancang untuk memberikan pengalaman analisis data yang terstruktur dan mudah digunakan oleh perusahaan properti, yaitu Tentang Aplikasi, Data, dan Analisis & Klasterisasi sesuai dengan gambar 4.16. Ketiga fitur ini saling terintegrasi untuk mendukung proses pemahaman perilaku pelanggan berdasarkan data pembayaran dan informasi properti.


Fitur pertama adalah Tentang Aplikasi, yang berfungsi sebagai halaman pengantar bagi pengguna untuk memahami tujuan dan dasar pengembangan aplikasi. Di bagian ini, dijelaskan bahwa Propalysis dibangun untuk membantu perusahaan dalam menganalisis pola pembayaran pelanggan menggunakan pendekatan machine learning. Metode yang digunakan, yaitu *X-Means*, juga dijelaskan secara singkat agar pengguna mengetahui landasan analitik yang digunakan. Selain itu, dijabarkan pula bagaimana aplikasi ini dapat berkontribusi dalam pengambilan keputusan bisnis yang lebih tepat sasaran.

Fitur kedua adalah Data, yang menyajikan informasi seputar dataset yang digunakan dalam proses analisis. Terlihat pada gambar 4.17. pada halaman ini, pengguna dapat melihat struktur data yang terdiri dari catatan transaksi pelanggan dan atribut properti yang relevan. Terdapat juga penjelasan mengenai proses *preprocessing* yang telah dilakukan sebelumnya, seperti pembersihan data, transformasi fitur, dan pemilihan fitur yang penting untuk proses klasterisasi.



**Gambar 4.17.** Halaman Fitur Data

Fitur ini penting karena memberikan konteks bagi pengguna untuk memahami latar belakang hasil analisis yang ditampilkan pada bagian berikutnya.



**Gambar 4.18.** Halaman Fitur Analisis & Klasterisasi

Fitur ketiga adalah Analisis & Klasterisasi. Pada bagian ini, terlihat pada gambar 4.18 pengguna dapat melihat hasil dari proses segmentasi pelanggan berdasarkan algoritma *X-Means*. Hasil klaster ditampilkan dalam bentuk visual yang informatif, sehingga memudahkan pengguna untuk memahami perbedaan karakteristik antar kelompok pelanggan. Misalnya, klaster tertentu mungkin menggambarkan pelanggan dengan riwayat pembayaran tepat waktu, sedangkan klaster lain menunjukkan pelanggan yang cenderung menunggak, penjelasan ini dilengkapi dengan grafik.

## BAB V

### PENUTUP

#### 5.1. Kesimpulan

Penelitian ini berhasil mengelompokkan data pelanggan ke dalam 3 klaster dengan pola perilaku pembayaran menggunakan metode klasterisasi *X-Means*. Berikut adalah kesimpulan yang didapat dari analisis:

1. Permasalahan bisnis yang dihadapi perusahaan terkait keterlambatan pembayaran pelanggan berimplikasi pada terganggunya arus kas serta peningkatan risiko piutang. Segmentasi pelanggan diperlukan sebagai strategi mitigasi risiko dan optimalisasi arus kas perusahaan.
2. Data historis pembayaran pelanggan yang digunakan dalam penelitian diperoleh dari catatan transaksi perusahaan, dengan memastikan relevansinya melalui seleksi fitur utama seperti jumlah keterlambatan, status pelunasan, jumlah pembayaran, dan total transaksi.
3. Proses preprocessing data dilakukan dengan langkah normalisasi, pembersihan data kosong, serta pemilihan fitur yang relevan. Tahapan ini memastikan bahwa data bersih, konsisten, dan siap digunakan dalam analisis *Clustering*.
4. Metode *X-Means* berhasil diterapkan untuk melakukan segmentasi pelanggan berdasarkan pola pembayaran. Kelebihan metode ini adalah kemampuannya dalam waktu komputasi yang lebih cepat dari pada metode pembandingan.
5. Evaluasi kualitas klaster dilakukan menggunakan metrik *Silhouette Score* **0,606**, *Davies-Bouldin Index* **0,538**, dan *Calinski-Harabasz Index* **472,924**. Nilai tersebut menunjukkan bahwa klaster yang terbentuk memiliki kualitas yang cukup baik dan dapat merepresentasikan pola pembayaran pelanggan secara jelas.
6. Hasil interpretasi segmentasi menunjukkan terbentuknya tiga klaster dengan karakteristik berbeda:
  - **Klaster 0 (41,5%):** Risiko rendah–menengah, rata-rata keterlambatan 4,2 hari, seluruhnya belum melunasi kewajiban.

- **Klaster 1 (23,3%):** Segmen premium dengan risiko rendah, rata-rata keterlambatan 2,6 hari, tingkat pelunasan 100%.
- **Klaster 2 (35,2%):** Risiko tinggi, rata-rata keterlambatan 14,8 hari, meskipun 96,3% sudah melunasi kewajiban.

Dengan demikian, penelitian ini membuktikan bahwa metode *X-Means* bisa diterapkan dalam segmentasi pelanggan berdasarkan pola pembayaran dan dapat diimplementasikan dalam bentuk aplikasi analitik berbasis web seperti Propalysis.

## 5.2. Saran Pengembangan

Berdasarkan hasil penelitian dan implementasi web *Propalysis* dalam menganalisis segmentasi pelanggan menggunakan metode *X-Means Clustering*, terdapat beberapa saran pengembangan yang dapat dilakukan untuk penelitian dan sistem di masa mendatang:

1. Penelitian selanjutnya disarankan menambahkan fitur lain seperti tipe unit, lokasi, usia properti, serta data demografis pelanggan agar segmentasi lebih akurat.
2. Web *Propalysis* dapat dikembangkan agar terintegrasi dengan sistem perusahaan (CRM atau penagihan) sehingga hasil klasterisasi langsung mendukung strategi pemasaran dan penagihan.
3. Antarmuka aplikasi perlu dilengkapi visualisasi interaktif (grafik, filter, dashboard) untuk memudahkan analisis dan pengambilan keputusan.
4. Model dan aplikasi berpotensi diterapkan di sektor lain dengan pola pembayaran serupa, seperti leasing, pendidikan, atau pembiayaan konsumen.



## DAFTAR PUSTAKA

- [1] W. Gao, S. Wei, C. Geng, J. He, X. Li, and S. Liu, "The Role of the Real Estate Sector in the Economy: Cross-National Disparities and Their Determinants," *Sustain.*, vol. 16, no. 17, 2024, doi: 10.3390/su16177697.
- [2] A. Suyatno, S. Arief, M. Asir, M. A. Anwar, and M. D. Sanusi, "Penerapan Strategi Segmenting dan Targeting dalam meningkatkan Kinerja Pemasaran: Literatur review," *J. Econ. Bussines Account.*, vol. 6, no. 2, pp. 1598–1609, 2023, doi: 10.31539/costing.v6i2.5434.
- [3] Y. You, Y. Hu, W. Yang, and S. Cao, "Research on the Influence Path of *Online Consumers' Purchase Decision Based on Commitment and Trust Theory*," *Front. Psychol.*, vol. 13, no. August, pp. 1–7, 2022, doi: 10.3389/fpsyg.2022.916465.
- [4] A. Jebbouri, "CRM Platforms Use in Real Estate Agencies and Improved Customer Satisfaction: A Systematic Literature Review," 2025.
- [5] B. E. Adiana, I. Soesanti, and A. E. Permanasari, "Analisis Segmentasi Pelanggan Menggunakan Kombinasi Rfm Model Dan Teknik *Clustering*," *J. Terap. Teknol. Inf.*, vol. 2, no. 1, pp. 23–32, 2018, doi: 10.21460/jutei.2018.21.76.
- [6] R. Rahmadhan and M. Wasesa, "Segmentation using Customers Lifetime Value: Hybrid *K-Means Clustering* and Analytic Hierarchy Process," *J. Inf. Syst. Eng. Bus. Intell.*, vol. 8, no. 2, pp. 130–141, 2022, doi: 10.20473/jisebi.8.2.130-141.
- [7] Melizah, A. A. T. Susilo, N. Lestari, and Elmayati, "Implementasi Algoritma *K-Means Clustering* Untuk Analisis Data Nilai Akademik Mahasiswa," vol. 16, no. 2, p. 84, 2024.
- [8] N. Naeem, I. A. Rana, and A. R. Nasir, "Digital real estate: a review of the technologies and tools transforming the industry and society," *Smart Constr. Sustain. Cities*, vol. 1, no. 1, pp. 1–21, 2023, doi: 10.1007/s44268-023-00016-0.
- [9] T. M. Fahrudin, P. A. Riyantoko, K. M. Hindrayani, and M. H. P. Swari, "Cluster Analysis of Hospital Inpatient Service Efficiency Based on BOR, BTO, TOI, AvLOS Indicators using Agglomerative Hierarchical *Clustering*," *Telematika*, vol. 18, no. 2, p. 194, 2021, doi: 10.31315/telematika.v18i2.4786.
- [10] B. Bustami, R. Mahara, H. Ahmadian, S. Wahyuni, and K. AR, "Analisis *Clustering* Penduduk Miskin Di Provinsi Aceh Menggunakan Algoritma *K-Means* Dan *X-Means*," *J. Nas. Komputasi dan Teknol. Inf.*, vol. 5, no. 1, pp. 26–35, 2022, doi: 10.32672/jnkti.v5i1.3961.
- [11] D. Pelleg, "E cient Estimation of the Number of Clusters *X -means* : Extending *K -means* with," *Sch. Comput. Sci.*, 2002.
- [12] S. I. Murpratiwi, I. G. Agung Indrawan, and A. Aranta, "Analisis Pemilihan

- Cluster Optimal Dalam Segmentasi Pelanggan Toko Retail,” *J. Pendidik. Teknol. dan Kejuru.*, vol. 18, no. 2, p. 152, 2021, doi: 10.23887/jptk-undiksha.v18i2.37426.
- [13] G. B. Kaligis and S. Yulianto, “Analisa Perbandingan Algoritma *K-Means*, *K-Medoids*, Dan *X-Means* Untuk Pengelompokan Kinerja Pegawai,” *IT-Explore J. Penerapan Teknol. Inf. dan Komun.*, vol. 1, no. 3, pp. 179–193, 2022, doi: 10.24246/itexplore.v1i3.2022.pp179-193.
- [14] M. Rizqi Sulistio, N. Suarna, and O. Nurdiawan, “Analisa Penerapan Metode *Clustering X-Means* Dalam Pengelompokan Penjualan Barang,” *J. Teknol. Ilmu Komput.*, vol. 1, no. 2, pp. 37–42, 2023, doi: 10.56854/jtik.v1i2.49.
- [15] G. S. Depari, “Real Estate Segmentation: A Model of Real Estate Decision Support System,” *Sang Pencerah J. Ilm. Univ. Muhammadiyah But.*, vol. 7(2), pp. 233–250, 2021, [Online]. Available: [https://id.wikipedia.org/wiki/Sang\\_Pencerah#/media/Berkas:Sang\\_Pencerah.jpg](https://id.wikipedia.org/wiki/Sang_Pencerah#/media/Berkas:Sang_Pencerah.jpg)
- [16] R. Adhitama, A. Burhanuddin, and A. Febriani, “Penerapan *X Means Clustering* Pada UMKM Kab Banyumas Yang Mendukung Mega Shifting Consumer Behavior Akibat Covid-19,” *J. Informatics, Inf. Syst. Softw. Eng. Appl.*, vol. 4, no. 1, pp. 71–80, 2022, doi: 10.20895/inista.v4i1.429.
- [17] E. Nurelasari, “Segmentasi Dan Klasifikasi Perilaku Pembayaran Pelanggan Pada,” vol. XXI, no. 1, pp. 69–76, 2019, doi: 10.31294/p.v20i2.
- [18] R. Muchtasar, Ilham, and H. Yusuf, “Implementasi Undang-Undang Nomor 1 Tahun 2011 tentang Perumahan dan Kawasan Permukiman dalam Penyelenggaraan Perumahan di Kelurahan Anduonohu Kota Kendari,” *Halu Oleo Law Rev.*, vol. 7, no. 2, pp. 167–178, 2023, doi: 10.33561/holrev.v7i2.24.
- [19] M. Nur, . R., and A. A. Adiningrat, “Penerapan Akad Istishna’ Pada Pengadaan Rumah Properti Syariah Pt. Syahada Muslim Group,” *J. Ilm. Manaj. “E M O R,”* vol. 6, no. 2, p. 274, 2023, doi: 10.32529/jim.v6i2.1996.
- [20] I. Bintang and A. Suman, “Dinamika Implementasi Akad Jual Beli Properti Syariah Non Bank,” *Islam. Econ. Financ. Focus*, vol. 2, no. 1, pp. 53–68, 2023, doi: 10.21776/ieff.2023.02.01.06.
- [21] I. Nurlaeli, “Pengaruh Minat Dan Kebiasaan Belajar Terhadap Prestasi Belajar Siswa Pada Mata Pelajaran Ilmu Pengetahuan Sosial Kelas V Sd Negeri Sudimara,” *Balanc. Econ. Business, Manag. Account. J.*, vol. XVII, no. 2, pp. 156–161, 2014.
- [22] D. A. Prasetya, A. P. Sari, M. Idhom, and A. Lisanthoni, “Optimizing *Clustering Analysis* to Identify High-Potential Markets for Indonesian Tuber Exports,” *Indones. J. Electron. Electromed. Eng. Med. Informatics*, vol. 7, no. 1, pp. 113–122, 2025, doi: 10.35882/skzqbd57.
- [23] Y. Meng, “YUNMENGBLO G ’ S Faktor penetapan Segmentasi Pasar.”
- [24] Y. Kurniawati, “Menerapkan Analisis Non-Hirarki Metode *K- Means 5.*” [Online]. Available: <https://images.app.goo.gl/6968pk83mnLoqJPA>

- [25] H. Qian, Q. Wen, L. Sun, J. Gu, Q. Niu, and Z. Tang, "RobustScaler: QoS-Aware Autoscaling for Complex Workloads," in *2022 IEEE 38th International Conference on Data Engineering (ICDE)*, 2022, pp. 2762–2775. doi: 10.1109/ICDE53745.2022.00252.
- [26] P. A. Riyantoko, K. M. Hindrayani, T. M. Fahrudin, and E. M. Safitri, "Southeast Asia Happiness Report in 2020 Using Exploratory Data Analysis," *Netw. Secur. Inf. Syst.*, vol. 2, no. 1, pp. 16–21, 2020.
- [27] Solihat Aprilianti, "Pengelompokan Kabupaten/Kota di Jawa Barat," 2024, [Online]. Available: [https://eprints.unpak.ac.id/8767/1/Skripsi\\_064120006\\_Aprilianti Solihat](https://eprints.unpak.ac.id/8767/1/Skripsi_064120006_Aprilianti%20Solihat)
- [28] D. Arizki Kuswardana, D. Arman Prasetya, and I. Gede Susrama Mas Diyasa, "Comparison of Elbow and Silhouette Methods in Optimizing K-Prototype *Clustering* for Customer Transactions," *J. Ilm. Educ. Pendidik. dan Inform.*, vol. 12, no. 1, pp. 43–48, 2025, [Online]. Available: <https://doi.org/10.21107/edutic.v12i1.29744>
- [29] T. T. Hmwe, N. Y. T. Thein, and K. M. Cho, "Improving *Clustering* quality using silhouette score," *J. Comput. Appl. Res.*, vol. 1, no. 1, pp. 58–62, 2020.
- [30] K. R. Shahapure and C. Nicholas, "Cluster quality analysis using silhouette score," *Proc. - 2020 IEEE 7th Int. Conf. Data Sci. Adv. Anal. DSAA 2020*, pp. 747–748, 2020, doi: 10.1109/DSAA49011.2020.00096.
- [31] I. F. Ashari, R. Banjarnahor, D. R. Farida, S. P. Aisyah, A. P. Dewi, and N. Humaya, "Application of Data Mining with the *K-Means Clustering* Method and Davies Bouldin Index for Grouping IMDB Movies," *J. Appl. Informatics Comput.*, vol. 6, no. 1, pp. 07–15, 2022, doi: 10.30871/jaic.v6i1.3485.
- [32] M. Mughnyanti, S. Efendi, and M. Zarlis, "Analysis of determining *centroid Clustering X-Means* algorithm with davies-bouldin index evaluation," *IOP Conf. Ser. Mater. Sci. Eng.*, vol. 725, no. 1, 2020, doi: 10.1088/1757-899X/725/1/012128.
- [33] Y. Wang, Y. Xu, and T. Gao, "Evaluation Method of Wind Turbine Group Classification Based on Calinski Harabasz," in *2021 IEEE 5th Conference on Energy Internet and Energy System Integration (EI2)*, 2021, pp. 2630–2635. doi: 10.1109/EI252483.2021.9713300.
- [34] I. F. Ashari, E. Dwi Nugroho, R. Baraku, I. Novri Yanda, and R. Liwardana, "Analysis of Elbow, Silhouette, Davies-Bouldin, Calinski-Harabasz, and Rand-Index Evaluation on *K-Means* Algorithm for Classifying Flood-Affected Areas in Jakarta," *J. Appl. Informatics Comput.*, vol. 7, no. 1, pp. 89–97, 2023, doi: 10.30871/jaic.v7i1.4947.

*Halaman ini sengaja dikosongkan*

## LAMPIRAN

### Lampiran 1. Data Penelitian



**Lampiran 2.** Kode Script

**Lampiran 3.** Script Pembuatan *Interface*

## Lampiran 4. LoA Artikel



Journal of Information System and Technology Research  
P ISSN 2828-3864; E ISSN: 2828-2973/  
<https://journal.aira.or.id/index.php/jistr>

AIRA

All Institute of Research and Publications  
<https://sinta.kemdikbud.go.id/journals/profile/15336>



Dear Author:

Edein Fortuna\*, Dwi Arman Prasetya and Kartika Maulida Hindrayani

It's my pleasure to inform you that, after peer review, your paper "**X-Means Clustering Algorithm in Property Customer Payment Pattern**" has been ACCEPTED with minor Revision and to be published JISTR: Journal of Information System and Technology Research E-ISSN : 2828-2973 (online), and it will be available online at <https://journal.aira.or.id/index.php/jistr>. Vol 4, No.3 (2025)

We inform you that JISTR: Journal of Information System and Technology Research is a journal that has been indexed by Google Scholar, Crossref, Garuda, PKP Index, Moraref, WorldCat, Base, Scientific Indexing Service, Sinta 4 (Decree of the Director General of Research, Technology and Higher Education Development RI Number : 10/C/C3/DT.05.00/2025)

Thank you very much for submitting your article to the JISTR: Journal of Information System and Technology Research E-ISSN : 2828-2973 (online). I believe that our collaboration will help to accelerate the global knowledge creation and sharing one step further.

Medan 11 July 2025

Editor-in-Chief



**Ali Ikhwan**

Dosen Pembimbing I

Dosen Pembimbing II

Dr. Eng. Ir. Dwi Arman Prasetya.,  
ST., MT., IPU., Asean. Eng

Kartika Maulida Huldrayani S.Kom,  
M.Kom